Module 2 random variable

Def 2.1 (random variable)

对于 probability space $(\Omega, \mathcal{F}, \mathbb{P})$, 一个 random variable 是一个 **Borel measurable function** $X : \Omega \to \mathbb{R}$. ♣

Remark 回顾 measurable function 的定义: 即对于任意 Borel set $B \subset \mathbb{R}$, 有 $X^{-1}(B) \in \mathcal{F}$. 例如: $X(\omega) = \omega^2$ 是一个 measurable function, 因为对于任意 Borel set $B \subset \mathbb{R}$, 有 $X^{-1}(B) = \{\omega \in \Omega | \omega^2 \in B\} \in \mathcal{F}$.

Proposition 2.1

Prob space $(\Omega, \mathcal{F}, \mathbb{P})$ 上的 random variables $X_1, X_2, \ldots, X_k : \Omega \to \mathbb{R}$, 任取 Borel measurable function $g : \mathbb{R}^k \to \mathbb{R}$,

$$\begin{aligned} X : \Omega &\to \mathbb{R} \\ \omega &\mapsto g(X_1(\omega), X_2(\omega), \ldots, X_k(\omega)) \end{aligned}$$

也是一个 random variable. ♠

Proof 我们在 measure theory 中证明过: 对于任意的 finite seq of Borel measureable functions $(f_i : \Omega \to \mathbb{R})_{i=1}^k$, 其各作为一个维度组成的函数 $f = (f_1, \cdots, f_k)$ 也是一个 Borel measurable function (from Ω 到 $\mathbb{R}^k$).

而这里的 X 就是 $g \circ f$, 是两个 Borel measurable function 的 composition, 因而也是一个 Borel measurable function (即 random variable).

Remark 以一种 Borel measurable 的方式组合多个 random variables, 这个函数也仍然是一个 random variable.

2.1 distributions

2.1.1 distribution and cumulative distribution function

Def 2.2 (probability distribution)

对于 random variable $X : \Omega \to \mathbb{R}$ on $\Omega, \mathcal{F}, \mathbb{P}$, 其 probability distribution 是 X 对于 $\mathbb{P}$ 的 pushforward measure, 记作 $\mathbb{P}^X : \mathcal{B}(\mathbb{R}) \to [0, 1]$. 即

$$\mathbb{P}^X(B) := \mathbb{P}(X^{-1}(B)), \quad \forall B \in \mathcal{B}(\mathbb{R})$$

我们 write:

$$X \sim \mathbb{P}^X$$

♣

Remark 看着有点不直观. 实则我们拆解:

- $X^{-1}(B)$ 即: 有多少 samples (即哪一个事件 $E \in \mathcal{F}$) 在这个 RV X 的映射下落入 B 这个区间?
- $\mathbb{P}(X^{-1}(B))$ 即: 这个事件 E 的概率是多少?

接下来的定义和例子会更加直观.

Def 2.3 (distribution function (也称 cumulative distribution function, cdf))

对于 random variable $X : \Omega \to \mathbb{R}$, 其 **cumulative distribution function** 是 $\mathbb{P}^X$ 这一函数的 distribution function, 记作 F_X. 即对于任意 $x \in \mathbb{R}$, 有

$$F_X(x) := \mathbb{P}^X((-\infty, x]) = \mathbb{P}(X^{-1}((-\infty, x]))$$

♣

Remark $F_X(x)$ 即 $\mathbb{P}(\{X \le x\})$ 我们也会简写为 $\mathbb{P}(X \le x)$.
$F_X(x)$ 的意义是: random variable X 的值不超过 x 的概率.

Example 2.1 (geometric probability) Fix $a, b > 0$. 我们在正方形区域 $\Omega = [0, a] \times [0, b]$ 上均匀地随机选取一个点 (x, y).
我们 define 随机变量: $X : \Omega \to \mathbb{R}$ by $X(x, y) = x$. 求 X 的 distribution function F_X.
这很简单: 对于 $x \in [0, a]$,

$$F_X(x) = \mathbb{P}(X \le x) = \frac{m([0, x] \times [0, b])}{m([0, a] \times [0, b])} = \frac{x \cdot b}{a \cdot b} = \frac{x}{a}, \quad 0 \le x \le a$$

因为

$$F_X(x) = \begin{cases} 0, & x < 0 \\ \frac{x}{a}, & 0 \le x \le a \\ 1, & x > a \end{cases} \tag{2.1}$$

注意: 在这个例子中, probability measure P 是 Lebesgue measure on $[0, a] \times [0, b]$. 很多时候我们在计算 RV 的 distribution function 的时候, 都是直接直观地计算 $P(X \le x)$. 但是在稍微复杂一些的例子中, 我们需要对各个条件的 formalization 更清楚一点.

Theorem 2.1 (distribution function 的性质)

对于 random variable $X : \Omega \to \mathbb{R}$, 其 distribution function F_X 满足:

- F_X 是 non-decreasing (non-strictly increasing) 的.
- $\lim_{x \to +\infty} F_X(x) = 1$, $\lim_{x \to -\infty} F_X(x) = 0$.
- F_X 是 right-continuous 的. 即对于任意 x_0, 有 $\lim_{x \to x_0^+} F_X(x) = F_X(x_0)$.
- 对于任意 x_0, 有 $\lim_{x \to x_0^-} F_X(x) = P(X < x_0)$. 并且 $\mathbb{P}(X = x_0) = \lim_{x \to x_0^+} F_X(x) - \lim_{x \to x_0^-} F_X(x)$.
- 对于任意 $x_1 < x_2$, 有 $P(X \in (x_1, x_2]) = F_X(x_2) - F_X(x_1)$.

♡

Proof 其他都显然. right-continuity 是源自 measure 的 continuity from above, 我们证明一下: 考虑一个单调递减序列 $\{x_n\} \downarrow x_0$, 令 seq of events $A_n = \{X \le x_n\}$, 注意这是一个嵌套递减的 set seq. 通过 $\mathbb{R}$ 的 completeness 容易证明:

$$A_0 = \bigcap_{n=1}^{\infty} A_n = \{\omega : X(\omega) \le x_0\}$$

由 measure 的 continuity from above, $\mathbb{P}(A_0) = \lim_{n \to \infty} \mathbb{P}(A_n)$. 也即 $\lim_{x \to x_0^+} F_X(x) = \mathbb{P}(X \le x_0)$.
而下面一条 $\lim_{x \to x_0^-} F_X(x) = \mathbb{P}(X < x_0)$ 同理是源自 measure 的 continuity from below.
那么 $\mathbb{P}(X = x_0) = \mathbb{P}(X \le x_0) - \mathbb{P}(X < x_0)$ 是 natural 的 (by def).

Remark 我们此时心里会默认一件事情: 一旦知道了 RV X 的 distribution function F_X, 就知道了 X 的完整 distribution P^X. 这个直觉是对的.
回忆一下: 我们在 measure theory 中, 证明 Carathéodory extension theorem 的时候, 证明过一个 $\pi-\lambda$ theorem, 以它作为工具才把 premeasure 从一个 algebra extend 到一个 measure on the generated σ-algebra:

Theorem 2.2 (Dynkin's $\pi-\lambda$ theorem)

设 $\mathcal{P}$ 是一个 π-system (closed under finite intersection), $\mathcal{L}$ 是一个 λ-system (closed under complementation and countable disjoint union), 如果 $\mathcal{P}\subseteq\mathcal{L}$, 那么 $\sigma(\mathcal{P})\subseteq\mathcal{L}$. ♡

我们考虑所有的 half-open interval $(-\infty,x]$ 组成的集合 $\mathcal{G}$, 这个集合 generate the Borel σ-algebra, 并且还是一个 π-system, 即: 它 closed under finite intersection:

$$(-\infty,a]\cap(-\infty,b]\in\mathcal{G},\quad \forall a,b\in\mathbb{R}$$

然后考虑

$$\mathcal{L}:=\{E\in\sigma(\mathcal{G}):\mathbb{P}_1(E)=\mathbb{P}_2(E)\}$$

即两个 measure 一致的 collection of sets. 容易证明, 这个 $\mathcal{L}$ 是一个 λ-system, 并且 $\mathcal{G}\subset\mathcal{L}$.
从而,

$$\mathbb{B}(\mathbb{R})=\sigma(\mathcal{G})\subseteq\mathcal{L}$$

并且 $\mathbb{P}_1(E)=\mathbb{P}_2(E)$ 对于任意 $E\in\mathbb{B}(\mathbb{R})$.
因而:

Corollary 2.1 (distribution function F_X determines distribution $\mathbb{P}^X$)

对于 random variable $X:\Omega\to\mathbb{R}$, 其 distribution function F_X 确定了 distribution $\mathbb{P}^X$; 即如果两个 random variable X 和 Y 满足 $F_X=F_Y$, 那么 $\mathbb{P}^X=\mathbb{P}^Y$. ♡

2.1.2 discrete random variable 与 probability mass function

我们基本上研究两类 random variable: discrete random variable 和 continuous random variable.

Def 2.4 (discrete random variable)

对于 random variable $X:\Omega\to\mathbb{R}$, 如果存在一个 countable set $S\subseteq\mathbb{R}$ 使得 $\mathbb{P}(X\in S)=1$, 那么 X 是一个 discrete random variable. ♣

Remark 就是说, X **的 range a.s. 是 countable 的** (允许 null set 上的值不在这个 countable set 里, 但是这是 measure theory 下的概念, 所以这些都可以忽略不计).
Remark 对于 discrete random variable X, 其 distribution function F_X 是一个 step function, 只有 countable 多个 jump discontinuity, 每个 jump 的大小就是 X 在那个点的 probability mass.
因而, 对于 discrete random variable X, 通常考虑其 **probability mass function (pmf)** p_X 更加有用:

Def 2.5 (probability mass function (pmf))

对于 discrete random variable X, 其 pmf 定义为

$$p_X(x):=\mathbb{P}(X=x),\quad \forall x\in\mathbb{R}$$

♣

这个 pmf 就是 F_X 的 jump size function. 当然, 根据定义明显可得:

$$\sum_x p_X(x) = 1$$

值得一提的是, 这个 **pmf 其实就是 X 的 distribution $\mathbb{P}^X$ 对于 counting measure (for range of X) 的 Radon-Nikodym derivative:**

Proposition 2.2 (pmf 是 distribution 对于 counting measure μ_S 的 Radon-Nikodym 导数)

对于一个 discrete random variable X, 假设其 range 是 countable set S, 则我们定义 counting measure μ_S on S 为:

$$\mu_S(A) := \sum_{x_i \in S} \mathbf{1}_A(x_i)$$

那么, distribution $\mathbb{P}^X \ll \mu_S$ (绝对连续), 并且有:

$$p_X = \frac{d\mathbb{P}^X}{d\mu_S}$$

♠

Proof 这很容易证明. 首先, 这个 counting measure 即: A 中有多少个点在 S 中.
那么显然, 如果 $\mu_S(A) = 0$, 即 A 中没有点在 S 中, 那么 $\mathbb{P}^X(A) = 0$. 因而 $\mathbb{P}^X \ll \mu_S$.
且对于任意 Borel set A,

$$\mathbb{P}^X(A) = \sum_{x_i \in A} \mathbb{P}(X = x_i) = \sum_{x_i \in A \cap S} p_X(x_i) = \int_A p_X(x)\, d\mu_S(x)$$

2.1.3 continuous random variable 与 probability density function

相对应 discrete random variable, 我们定义 continuous random variable:

Def 2.6 (continuous random variable)

我们称一个 random variable $X : \Omega \to \mathbb{R}$ 是一个 **continuous random variable**, 如果它的 cdf F_X 是一个 **absolutely continuous function.**

♣

Remark 回顾 absolutely continuous function 的定义, 这是一个比较复杂的定义: 对于任意 $\epsilon > 0$, 都存在 $\delta > 0$ 使得任取 finite collection of disjoint intervals $\{(a_i, b_i)\}$, 都满足:

$$\sum_i (b_i - a_i) < \delta \implies \sum_i |F_X(b_i) - F_X(a_i)| < \epsilon$$

这是 uniform continuity 的一个加强版本. uniform continuity 对应的是 $n = 1$ 的情况, 即: **任意的区间上, 只要长度足够小, 就能保证 F_X 在这个区间上的增量足够**小; 而 absolutely continuity 更严格: **即便是任意数量的分散的区间, 只要总长度足够小, 就能保证 F_X 在这些 interval 上的增量的总和足够小.**
这个定义有点麻烦, 不过存在等价的条件. 为此我们要 recall 一系列定义与结论, 详细请见: notes on measure theory, module 12: differentiation on $\mathbb{R}$:

- 给定一个 function $F : \mathbb{R} \to \mathbb{C}$, 我们定义它的 **total variation function** $V_F : \mathbb{R} \to [0, +\infty]$ 为:

$$T_F(x) := \sup\Big\{ \sum_{i=1}^n |F(x_i) - F(x_{i-1})| \mid -\infty < x_0 < \cdots < x_n \Big\}$$

- 如果 $T_F(\infty) < \infty$ (注意这是单调递增函数, 因而即对于任意的 x 都有 $T_F(x) < \infty$), 那么我们称 F

是一个 **function of bounded variation**, 写作 $F \in BV$.

- 如果 $F \in BV$, 且 F 是 right-continuous 的, 且 $F(-\infty) = 0$, 那么我们称 $F \in NBV$. (即 normalized function of bounded variation).
- **任意的 $F \in NBV$ 都 m-a.e. differentiable, 且导数 $F' \in L^1(m)$**, 并且以下三个条件等价:

$$F \in AC \tag{2.2}$$

$$\iff \mu_F \ll m \tag{2.3}$$

$$\iff F(x) = \int_{-\infty}^{x} F'(t)\, dt \quad \forall x \in \mathbb{R} \tag{2.4}$$

这几行字浓缩了 measure theory 的 differentiation theory 的两个星期的内容... 具体见上文 notes 链接, 都有详细证明. 而我们这里就利用起最后这一条结论. 首先, 我们 state 一件事:

Lemma 2.1 (cdf 一定是 NBV 的)

任意的 random variable 的 cdf F_X 都是一个 NBV function. ♡

Proof 依旧见 notes, 有一个关键 lemma: $F \in BV$ 当且仅当它可以表示为两个 monotone increasing function 的差. 而 random variable 的 cdf F_X 自身是一个 non-decreasing function, 因而首先 $F_X \in BV$. 其次, 由 2.1 我们知道, F_X 是 right-continuous 的, 且 $F_X(-\infty) = 0$. 因而 $F_X \in NBV$.
因而我们自然得出:

Theorem 2.3 (一个 random variable 是 continuous random variable 的充要条件)

- 一个 random variable $X : \Omega \to \mathbb{R}$ 的 cdf 一定是 m-a.e. differentiable 的.
- X 是一个 continuous random variable 当且仅当 $\mathbb{P}^X \ll m$, 即当且仅当存在一个函数 $f_X : \mathbb{R} \to [0, \infty)$, 使得使得对于任意 Borel set $A \subseteq \mathbb{R}$, 有

$$\mathbb{P}^X(A) = \int_A f_X\, dm$$

  这个函数 f_X 即是:
  - **distribution 对于 Lebesgue measure 的 Radon-Nikodym derivative**: $f_X = \frac{d\mathbb{P}^X}{dm}$.
  - **cdf F_X 的 m-a.e. 导数 $f_X = F_X'$.**

  我们也称这个 f_X 是 continuous random variable X 的 **probability density function (pdf).** ♡

Proof 即 remark 的最后一条结论. 由于 F_X 是一个 NBV function, 因而 F_X 是 m-a.e. differentiable 的. 并且, $F_X \in AC$ iff 它满足 FTC of Lebesgue integral.

Remark 因而, 在简化的教材中, 通常会直接定义: 一个 random variable X 是 continuous random variable, 如果存在一个 f_X 使得 $F_X(x) = \int_{-\infty}^{x} f(t)\, dt$ for all x. 这里其实是跳过了我们刚才的所有步骤, 直接使用了这个等价条件. 因为这个条件也等价于:

$$F_X(x) = \int_{-\infty}^{x} F_X'(t)\, dt \quad \forall x \in \mathbb{R}$$

Def 2.7 (probability density function (pdf))

对于 continuous random variable X, 其 probability density function 定义为 F_X 的 (m-a.e.) 导数, 即

$$f_X(x) := F_X'(x), \quad m\text{-a.e. } x \in \mathbb{R}$$

♣

我们最后梳理一下.

- **任意的 random variable** 的 cdf F_X 都是一个 NBV function, 因而**一定 a.e. 可导**. 但是它的导数 F'_X 的积分不一定返回原函数.
- **如果一个 m-a.e. 导数 F'_X 满足 $F_X(x) = \int_{-\infty}^{x} F'_X(t)\ dt$ 对所有 $x \in \mathbb{R}$ 成立, 即导数的积分返回原函数, 那么 X 就是一个 continuous random variable**, 而我们定义 $f_X := F'_X$ 为 X 的 probability density function.

以及, 显然 pdf 有以下性质:

Proposition 2.3 (probability density function 的性质)

对于 continuous random variable X with pdf f_X,

- $f_X(x) \geq 0$ for m-a.e. $x \in \mathbb{R}$. (因为 F_X 是 non-decreasing 的.)
- $\int_{-\infty}^{+\infty} f_X(x)\ dx = 1$. (因为 $F_X(\infty) = 1$.)
- 对于任意 Borel set A, 有
$$\mathbb{P}(X \in A) = \mathbb{P}^X(A) = \int_A f_X(x)\ dx$$
- 对于 m-a.e. $x \in \mathbb{R}$,
$$f_X(x) = \lim_{\epsilon \to 0^+} \frac{\mathbb{P}^X([x, x+\epsilon))}{\epsilon} = \lim_{\epsilon \to 0^+} \frac{F_X(x+\epsilon) - F_X(x)}{\epsilon}$$

2.1.4 singular continuous random variable 与 Lebesgue Decomposition Theorem

对于 continuous random variable 的定义, 有些地方会简化定义为: continuous random variable 就是指其 cdf 是一个 continuous function.

但是我们现在知道, 这个定义是错的. 首先, 标准定义中的 absolutely continuous 要强于 continuous (它能推导出 a.e. differentiable); 而且, **这个更强的定义是 necessary 的**.

因为当提及 continuous random variable 时, 通常意思是它存在一个 pdf. 而存在一个 pdf 即意味着它满足 FTC of Lebesgue integral, 也就等价于 F_X 一定是一个 absolutely continuous function. 而仅仅 continuous 什么都无法保证.

我们这里给出一个 counterexample: Cantor distribution. 它的 cdf 是 continuous 的, 但是它并没有能够满足 FTC of Lebesgue integral (返回原函数) 的 a.e. derivative, 因而没有 pdf.

Example 2.2 (**Cantor distribution**)

令 X_n be 独立同分布 (i.i.d.) 的随机变量 $P(X_n = 0) = P(X_n = 2) = 1/2$. 然后定义:
$$X := \sum_{n=1}^{\infty} \frac{X_n}{3^n}$$

它刻画的是:

- 把 $[0, 1]$ 三等分, 去掉中间的部分, 然后在剩下的两部分中, 以 $1/2$ 的概率选择左边的区间, 以 $1/2$ 的概率选择右边的区间;
- 在选定的区间中, 再把它三等分, infinitely 重复这一过程.
- 最后, 这一行为会收敛于 Cantor set 上的一个点.

具体而言:

- 第 1 步 ($n=1$) 我们查看 $\frac{X_1}{3^1}$, 如果 $X_1=0$, 你选择了左边的区间 $[0,1/3]$; 如果 $X_1=2$, 你选择了右边的区间 $[2/3,1]$.
- 第 2 步 ($n=2$): 在第 1 步选定的区间内，查看 $\frac{X_2}{3^2}=\frac{X_2}{9}$ 如果 $X_2=0$, 你在当前小区间内选择了左侧的 1/3; 如果 $X_2=2$, 你在当前小区间内选择了右侧的 1/3.
- $\cdots$

从而, X 的 range 是 Cantor set, recall: 这是一个 measure zero 的 uncountable set, 其 cardinality 是 continuum (与 $\mathbb{R}$ 等势).

$$C=\{x\in[0,1]\mid x=(0.a_1a_2a_3\ldots)_3,\ \text{where } a_i\in\{0,2\}\}$$

它也表示了: 三进制小数中, 所有完全不包含数字 1 的小数的集合.

由于其 uncountability, 对于任意单点 x 都有 $\mathbb{P}(X=x)=0$, **因而 F_X 在 $\mathbb{R}$ 上处处连续**; 并且容易证明: **F_X 在 x 处的导数** $F_X'(x)=0$. (因为对于 C^c 中的任意被挖掉的区间, F_X 在这个区间上是 constant 的).

然而, $F_X'=0$ 却**不满足 FTC of Lebesgue integral**. 比如反例: $F_X(1)=1$, 但是

$$\int_{-\infty}^{1}F_X'(t)\,dt=0$$

因而 X 没有 pdf, 也就不是 continuous random variable.

对于 Cantor distribution 这个例子, 我们称这样的 random variable 是一个 **singular continuous random variable**:

Def 2.8 (singular continuous random variable)

对于 random variable $X:\Omega\to\mathbb{R}$, 如果 X 的 cdf F_X 是一个 continuous function, 并且 $\mathbb{P}^X\perp m$ (即存在一个 measure zero 的 Borel set N 使得 $\mathbb{P}^X(N)=1$, 也等价于 F_X 的导数 $F_X'=0$ a.e.), 那么我们称 X 是一个 singular continuous random variable. ♣

Remark singular continuous random variable 的意思是, 在 $\mathbb{R}$ 上, X 的值 a.s. 落在一个 measure zero 的 set 上, 也就是说它的 cdf 大部分是平的, 只有在 measure zero 的 set 上才有 jump.

这个例子向我们说明了: 除了 discrete random variable 和 continuous random variable 以外, 还有其他的奇异的 random variables. 而下面这一定理刻画了任意的 random variable 的结构:

Theorem 2.4 (Lebesgue Decomposition Theorem)

对于任意 random variable $X:\Omega\to\mathbb{R}$, 其 distribution $\mathbb{P}^X$ 可以唯一分解为三个 mutually singular 的 measure 的和:

$$\mathbb{P}^X=\mathbb{P}^X_{ac}+\mathbb{P}^X_{sc}+\mathbb{P}^X_{d}$$

其中 $\mathbb{P}^X_{ac}\ll m$ 是 absolutely continuous measure, $\mathbb{P}^X_{sc}\perp m$ 是一个 singular continuous measure, $\mathbb{P}^X_{d}\perp m$ 是 discrete measure. ♡

Proof TODO.

Remark 我们也可以这样展开:

$$F_X(x)=\int_{-\infty}^{x}f_{ac}(t)\,dt+\sum_{x_i\le x}p_d(x_i)+F_{sc}(x)$$

其中 f_{ac} 是 X_{ac} 的 pdf, p_d 是 X_d 的 pmf, 而 F_{sc} 由于其奇异性是无法分解的.

2.2 expectation and variance

随机变量的 **expectation** 是它 w.r.t. 它所在概率空间 prob measure $\mathbb{P}$ 的积分, 表示它的值的 prob-weighted average;
而其 **variance** 是 $(X - E(X))^2$ 这个 induced RV w.r.t. $\mathbb{P}$ 的积分, 表示 X 离它的值的 weighted average $\mathbb{E}(X)$ 的聚集程度:

Def 2.9 (expectation and variance of random variable)

对于 random variable $X : \Omega \to \mathbb{R}$, 其 expectation 定义为

$$\mathbb{E}[X] := \int_\Omega X \, d\mathbb{P}$$

其 variance 定义为

$$\mathrm{Var}(X) := \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_\Omega (X - \mathbb{E}[X])^2 \, d\mathbb{P}$$

♣

Remark $\int_\Omega d\mathbb{P} = \mathbb{P}(\Omega) = 1$, 因而 $\mathbb{E}[X]$ 可以看作是 X 的值的 weighted average, 其中权重就是每个 sample point 在这个原 prob space 上的概率.
Note that: $\mathbb{E}[X]$ 未必是 finite 的. $\mathbb{E}[X] < \infty \iff X \in L^1(\mathbb{P})$. $\mathrm{Var}(X) < \infty \iff X \in L^2(\mathbb{P})$
要计算 discrete random vairable 的 expectation 和 variance, 直接 by def, sum 就可以:

Proposition 2.4 (discrete random variable 的 expectation 和 variance)

对于 discrete random variable X with pmf p_X,

$$\mathbb{E}[X] = \sum_x x p_X(x), \quad \mathrm{Var}(X) = \sum_x (x - \mathbb{E}[X])^2 p_X(x)$$

♠

非常简单.
但是对于 continuous random variable 而言, 怎么求呢? 这里有一个 w.r.t. prob measure $\mathbb{P}$ 的积分, 有点难计算. 我们更希望计算 w.r.t. Lebesgue measure m 的积分, 这样就可以用一些经典的方法来算它了.
为了实现这个目标, 我们首先需要一个工具来过渡一下:

Lemma 2.2 (用 distribution (X 的 push-forward measure) 计算 expectation)

对于 random variable $X : \Omega \to \mathbb{R}$, 如果 X integrable, 那么其 expectation

$$\mathbb{E}[X] = \int_\mathbb{R} x \, d\mathbb{P}^X(x)$$

♡

Proof 这个结论是 Lebesgue integral 的 change of variable formula 的一个 special case. 注意, $X = \mathrm{id} \circ X$ ($\mathrm{id} : \mathbb{R} \to \mathbb{R}$ 是恒等函数).
By change of variable formula,

$$\int_\Omega X \, d\mathbb{P} = \int_\Omega (\mathrm{id} \circ X) \, d\mathbb{P} = \int_\mathbb{R} \mathrm{id}(x) \, d\mathbb{P}^X(x) = \int_\mathbb{R} x \, d\mathbb{P}^X(x)$$

(如果不用 change of variable theorem, 也可以证明. 考虑 simple function 的 case, 显然; 然后对 simple function 自然成立, 然后用 monotone convergence theorem 推广到一般情况.)
//TODO: 从 diffeomorphism version 的 change of variable formula 证明 push-forward version 的 change of variable formula, 然后 apply 这个结论. 参考: change of variable

Proposition 2.5 (continuous random variable 的 expectation 和 variance)

对于 continuous random variable X with pdf f_X, 如果 $\mathbb{E}[X]$ 和 $\mathrm{Var}(X)$ 都是 finite 的, 那么

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x)\, dx, \quad \mathrm{Var}(X) = \int_{-\infty}^{+\infty} (x - \mathbb{E}[X])^2 f_X(x)\, dx$$

并且, 对于任意的 measurable function $g : \mathbb{R} \to \mathbb{R}$, 都有

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) f_X(x)\, dx$$

♠

Proof 由于 $\mathbb{E}[X] = \int_{\mathbb{R}} x\, d\mathbb{P}^X(x)$, 而对于 ctn random variable,

$$d\mathbb{P}^X(x) = f_X(x)\, d\lambda(x)$$

从而得证.

Proposition 2.6 (expectation 的性质)

令 $X, Y : \Omega \to \mathbb{R}$ 为 **integrable** random variables, 则

- **linearity of expectation**: $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$ for any $a, b \in \mathbb{R}$.
- **monotonicity of expectation**: 如果 $X \le Y$ a.s., 那么 $\mathbb{E}[X] \le \mathbb{E}[Y]$.
- **absolute value**: $\mathbb{E}[X] \le \mathbb{E}[|X|]$

♠

这三条性质都容易验证, 直接 follow from linearity of Lebesgue integral, monotonicity of Lebesgue integral, triangle inequality of Lebesgue integral.

Proposition 2.7 (computing variance)

对于 random variable X with finite expectation,

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

♠

By def, 容易验证.

2.3 discrete random variables

Recall: discrete random variable 是指其 range a.s. 是 countable 的 random variable. (存在一个 countable set $S \subseteq \mathbb{R}$ 使得 $\mathbb{P}(X \in S) = 1$)

discrete RV 的 probability mass unction (pmf):

$$p_X(x) := \mathbb{P}(X = x), \quad \forall x \in \mathbb{R}$$

就是 X 的 distribution P^X 对于 counting measure of range S 的 Radon-Nikodym derivative:

$$p_X = \frac{d\mathbb{P}^X}{d\mu_S}$$

因为假设 X 的 range 是 $S = \{x_1, x_2, \ldots\}$, 那么对于任意 Borel set B,

$$\mathbb{P}^X(B) = \sum_{x_i \in B} \mathbb{P}(X = x_i) = \sum_{x_i \in B \cap S} p_X(x_i) = \int_A p_X(x)\, d\mu_S(x)$$

下面我们给出一些经典的 discrete random variable 的例子, 以及它们的 pmf 和 cdf.

2.3.1 Bernoulli distribution and Binomial distribution

Example 2.3 (**Bernoulli distribution**)
令 $\Omega := \{\omega_1, \omega_2\}$, $\mathcal{F} := 2^\Omega$.
令 $\mathbb{P}(\{\omega_1\}) = p$, $\mathbb{P}(\{\omega_2\}) = 1 - p$ 来表示这两个 singular 事件的概率.
令 $X(\omega_1) = 1$, $X(\omega_2) = 0$ 分别表示 success 和 failure.
那么显然可以计算:

$$\mathbb{P}(X = 0) = \mathbb{P}(\{\omega_2\}) = 1 - p, \quad \mathbb{P}(X = 1) = \mathbb{P}(\{\omega_1\}) = p$$

我们称 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一个 Bernoulli probability space (它 model 了一个 Bernoulli trial, 即一个 random experiment with two possible outcomes: success 和 failure)
称 $X : \Omega \to \{0, 1\}$ 这个 random variable 为一个 **Bernoulli random variable**, 并称 X 的 distribution P^X 为一个 **Bernoulli distribution**, 写作

$$X \sim \text{Ber}(p)$$

这是最简单的 random variable 和 distribution 了. 它 model 的是: 比如我们 toss 一枚 biased coin, 以 p 的概率得到 heads (success), 以 $1 - p$ 的概率得到 tails (failure).

Proposition 2.8
如果 $X \sim \text{Ber}(p)$, 那么 $\mathbb{E}[X] = p$, $\text{Var}(X) = p(1 - p)$.

显然.
Example 2.4 (**Binomial distribution**)
我们 independently repeat n 次 Bernoulli trial, 每次 trial 的 success probability 都是 p.
考虑:

$$S := X_1 + X_2 + \cdots + X_n$$

为 success 的总次数. 那么 S 是一个 discrete random variable $S : \Omega^n \to \mathbb{Z}_{\geq 0}$ 容易计算出 S 的 pmf:

$$p_S(k) = \mathbb{P}(S = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \ldots, n$$

我们称 S 的 distribution P^S 为一个 **Binomial distribution**, 写作

$$S \sim \text{Bin}(n, p)$$

它 model 的是: 比如我们 toss 一枚 biased coin n 次, 得到 heads 的总次数.

Proposition 2.9
如果 $S \sim \text{Bin}(n, p)$, 那么 $\mathbb{E}[S] = np$, $\text{Var}(S) = np(1 - p)$.

Proof

$$\mathbb{E}[X] = \sum_{k=1}^{n} k \cdot \mathbb{P}(X = k) = \sum_{k=1}^{n} k \cdot \binom{n}{k} p^k (1 - p)^{n-k} = p(1 - p)^{n-1} \sum_{k=1}^{n} k \cdot \binom{n}{k} (\frac{p}{1 - p})^{k-1}$$

由于

$$(1+t)^n = \sum_{k=0}^{n} \binom{n}{k} t^k \implies n(1+t)^{n-1} = \sum_{k=1}^{n} k \cdot \binom{n}{k} t^{k-1}$$

可以得到

$$\mathbb{E}[X] = p(1-p)^{n-1} \cdot n(1+\frac{p}{1-p})^{n-1} = np$$

然后计算得 $\mathrm{Var}(X) = np(1-p)$. 但是这是比较麻烦的方法. 也可以利用 $X = \sum_{i=1}^{n} X_i$, 其中 $X_i \sim \mathrm{Ber}(p)$ i.i.d 这个事实来计算, 那么直接通过线性叠加 Bernoulli random variable 的 expectation 和 variance 就可以了.

2.3.2 Geometric distribution and Negative Binomial distribution

Example 2.5 (**Geometric distribution**)
我们 perform independent Bernoulli trial, 每次 trial 的 success probability 都是 p.
考虑 random variable T 表示第一次 success 发生的 trial number. (也就是等于: 我们一直 trial, 直到第一次 success 发生, 那么这个 trial 的 number 就是 T).
那么 T 是一个 discrete random variable $T : \Omega^\infty \to \mathbb{Z}_{\geq 1}$.
容易计算出 T 的 pmf:

$$p_T(k) = \mathbb{P}(T = k) = (1-p)^{k-1}p, \quad k = 1, 2, \ldots$$

我们称 T 的 distribution P^T 为一个 **Geometric distribution**, 写作

$$T \sim \mathrm{Geom}(p)$$

它 model 的是: 比如我们 toss 一枚 biased coin, 第一次得到 heads 的 trial number.

Proposition 2.10
如果 $X \sim \mathrm{Geom}(p)$, 那么 $\mathbb{E}[X] = 1/p$, $\mathrm{Var}(X) = (1-p)/p^2$. ♠

Proof

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} k(1-p)^{k-1}p = p\sum_{k=1}^{\infty} k(1-p)^{k-1} = p\Big(-\frac{d}{d(1-p)}\sum_{k=0}^{\infty}(1-p)^k\Big) = -p - \frac{d}{dp}\frac{1}{1-(1-p)} = \frac{1}{p}$$

similarly, 可以计算得

$$\mathbb{E}[X^2] = \frac{2-p}{p^2}$$

因而

$$\mathrm{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{1-p}{p^2}$$

Example 2.6 (**Negative Binomial distribution**)
这是 Geometric distribution 的 generalization (但不完全一样).
我们 perform independent Bernoulli trial, 每次 trial 的 success probability 都是 p. (即 independent and identically distributed)
令 random variable T_r 表示第 r 次 success 发生之前的 failures 的数量. (也就是等于: 我们一直 trial, 直到第 r 次 success 发生, 那么这个 trial 的 number 就是 $T_r + r$, 因为 T_r 是 failures 的数量, 还要加上 $r-1$ 个

success.).

那么 T_r 是一个 discrete random variable $T_r : \Omega^\infty \to \mathbb{Z}_{\geq 0}$.

容易计算出 T_r 的 pmf:

$$p_{T_r}(k) = \mathbb{P}(T_r = k) = \binom{k+r-1}{k}(1-p)^k p^r, \quad k = 0, 1, 2, \ldots$$

这是因为: 最后一次 success 的位置是固定的. 我们要在前 $k+r-1$ 次 trial 中选择 k 次作为 failures.

我们称 T_r 的 distribution P^{T_r} 为一个 **Negative Binomial distribution**, 写作

$$T_r \sim \mathrm{NB}(r, p)$$

它 model 的是: 比如我们 toss 一枚 biased coin, 得到第 r 个 heads 之前会经历的 failures 的数量.

2.3.3 Poisson distribution

Example 2.7 (**Poisson distribution**) 考虑这一 pmf:

$$\mathbb{P}(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

我们称 X 的 distribution P^X 为一个 **Poisson distribution**, 写作

$$X \sim \mathrm{Poi}(\lambda), \quad \lambda > 0$$

以 $\lambda = 3$ 为例画出 pmf 示意图:

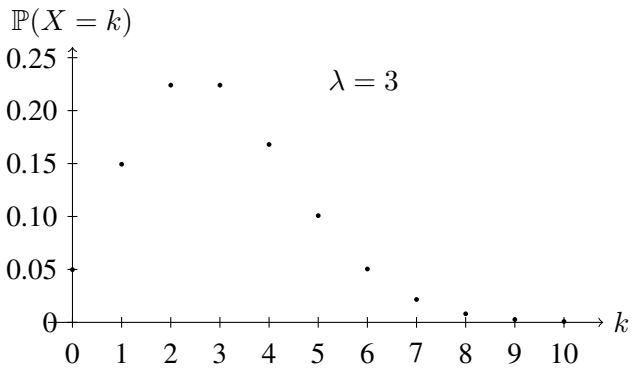

Remark 当 $n \to \infty$ 时, $\mathrm{Bin}(n, \lambda/n)$ 的 distribution 趋近于 $\mathrm{Poi}(\lambda)$.

考虑 $X \sim B\left(n, \frac{\lambda}{n}\right)$, 对于固定的 k:

$$\mathbb{P}(X = k) = \binom{n}{k}\left(\frac{\lambda}{n}\right)^k\left(1 - \frac{\lambda}{n}\right)^{n-k}$$

展开组合数 $\binom{n}{k}$:

$$\mathbb{P}(X = k) = \frac{n(n-1)\ldots(n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^n \cdot \left(1 - \frac{\lambda}{n}\right)^{-k}$$

重组项:

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} \cdot \underbrace{\frac{n(n-1)\ldots(n-k+1)}{n^k}}_{(1)} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^n}_{(2)} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{(3)}$$

其中, (1) 的 limit 是 1, (2) 的 limit 是 $e^{-\lambda}$, (3) 的 limit 是 1, 因而

$$\lim_{n\to\infty} \mathbb{P}(X=k) = e^{-\lambda}\frac{\lambda^k}{k!}$$

这个极限行为的意义是:

- λ 表示: 在一个固定时间/空间窗口内, 一个事件出现的平均次数的观测.
- 我们把这段时间间分成 n 个小窗口, 将这个观测作为先验知识用来 model 这类事件实现的平均概率, 那么每个小窗口内事件出现的概率是 $p=\lambda/n$.
- 每个 $\text{Bin}(n,\lambda/n)$ 都表示: 在时间细分成 n 个小窗口的情况下, 这个事件出现的次数的分布. (注意不是在时间上的分布, 而是在次数上的分布)
- 当 $n\to\infty$ 时, 其意义: 基于连续时间的估计, 这个事件在原固定事件窗口内出现的次数的分布. 这就是 $\text{Poi}(\lambda)$ 的意义.

因而 Poisson distribution 的意义本质上是: **给定对一个事件在固定窗口下出现的平均次数的观测 (估计), 那么这个事件在这个窗口内出现 n 次 ($n=0,1,2,\cdots$) 的概率是多少?**

所以 Poisson 分布, 即是**根据一个事件在给定 windows 内发生次数的 expectation, 来估计这个事件在该 windows 内发生次数的分布的标准方法.**

Remark

Further remark: Poisson distribution 的用途.

- 它是 model "大量级的小概率事件" 的通用模型.
  即一段时间内, 一件事情的发生的概率非常小 ($p\ll 1$), 但是有很多机会发生 ($n\gg 1$). 比如放射性衰变.
- 现实世界中, 对于一些事情, 我们想要 model 其在一段时间内发生的总次数 (n) 和单次成功率 (p) 是很困难的. 比如统计今天路过百货大楼的总人数 (n), 以及每个人路过百货大楼时走进去的概率 (p). 但是我们很容易可以知道: $\lambda=np$ 的观测. 即: 每天平均有多少人走进百货大楼. 那么我们就可以用 Poisson distribution 来 model 这件事情在一天内发生的次数的分布.

Proposition 2.11

如果 $X\sim\text{Poi}(\lambda)$, 那么 $\mathbb{E}[X]=\lambda$, $\text{Var}(X)=\lambda$.

Proof recall e^x 的 taylor expansion:

$$e^x = \sum_{k=0}^{\infty}\frac{x^k}{k!}$$

因而

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} ke^{-\lambda}\frac{\lambda^k}{k!} = e^{-\lambda}\lambda\sum_{k=1}^{\infty}\frac{\lambda^{k-1}}{(k-1)!} = e^{-\lambda}\lambda e^{\lambda} = \lambda$$

similarly, 可以计算得

$$\mathbb{E}[X^2] = \lambda^2+\lambda$$

因此,

$$\text{Var}(X) = \mathbb{E}[X^2]-(\mathbb{E}[X])^2 = \lambda$$

2.3.3.1 Poisson distribution 的 additivity

Theorem 2.5 (additivity of Poisson distribution)

如果 $X \sim \text{Poi}(\lambda_1)$, $Y \sim \text{Poi}(\lambda_2)$ are independent, 那么

$$X + Y \sim \text{Poi}(\lambda_1 + \lambda_2)$$

♡

Remark 这个事实通过简单的计算即可得到.
但是值得一提的是, 我们之后会证明一个结论: 两个 independent 的 random variable 的 sum 的 distribution 是它们 convolution 的 distribution.
而 Poisson distribution 的 convolution 仍然是 Poisson distribution, 并且是 linear 的. 这就是 additivity of Poisson distribution 的本质原因.

2.4 continuous random variables

recall: 总而言之, continuous random variable 是指其 distribution $\mathbb{P}^X$ 对于 Lebesgue measure m 是 absolutely continuous 的 random variable, 等价于存在一个 pdf f_X 使得

$$F_X(x) = \int_{-\infty}^{x} f_X(y)dy$$

对于任意 x 都成立.
而由 $\mathbb{E}[X] = \int_\Omega X d\mathbb{P} = \int_\mathbb{R} x d\mathbb{P}^X = \int_\mathbb{R} x f_X(x)dx$ 可得

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x)dx, \quad \text{Var}(X) = \int_{-\infty}^{+\infty} (x - \mathbb{E}[X])^2 f_X(x)dx$$

这里还有一个额外的结论:

Proposition 2.12

对于任意的 measurable function $g : \mathbb{R} \to \mathbb{R}$, 都有

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) f_X(x)dx$$

♠

Proof

$$\begin{aligned}
\mathbb{E}[g(X)] &= \int_\Omega g(X(w))\, d\mathbb{P}(w) \\
&= \int_\Omega g \circ X\, d\mathbb{P} \\
&= \int_\mathbb{R} g\, d\mathbb{P}^X \\
&= \int_{-\infty}^{+\infty} g(x) f_X(x)\, dx
\end{aligned}$$

下面我们介绍一些常见的 continuous random variables, 以及它们的 pdf, cdf, expectation 和 variance.

2.4.1 uniform distribution: 最简单的 continuous RV

Def 2.10 (uniform distribution)

如果 $f_X(x) = \frac{1}{b-a}$ on (a,b) and 0 elsewhere, 那么我们称 X 的 distribution P^X 为一个 **uniform distribution**, 写作

$$X \sim U([a,b])$$

♣

对于 uniform distribution, 很容易计算得:

$$F_X(x) = \frac{x-b}{b-a}, \quad \mathbb{E}[X] = \frac{a+b}{2}, \quad \mathrm{Var}(X) = \frac{(b-a)^2}{12}$$

Example 2.8 (uniform distribution 的 pdf 和 cdf)
考虑 $X \sim U([a,b])$, 其 pdf 和 cdf 的图像如下:

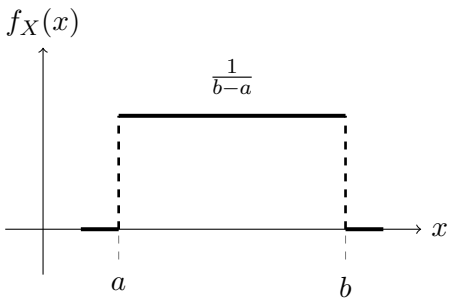

pdf: $f_X(x) = \frac{1}{b-a}$

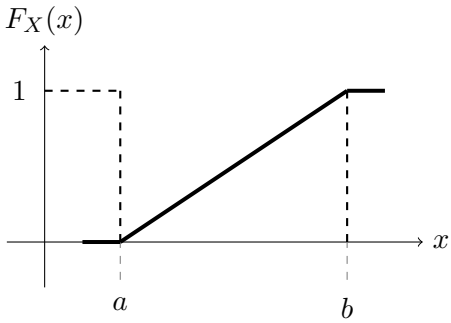

cdf: $F_X(x) = \frac{x-a}{b-a}$

2.4.2 exponential distribution: geometric distribution 的 continuous version

Exponential random variable model 的是一盏灯的 remaining lifetime. 它 assume: 任意时间, 这盏灯有一个 constant 的磨损速率.
假设它的磨损速率是 $\lambda = \lambda_X(t)$ for all t, 那么在任意时间 t 上:

$$\lambda_X(t) = \lim_{h\to 0^+} \frac{P(X \in (t, t+h])}{h} = \lim_{h\to 0^+} \frac{\mathbb{P}(t \le X \le t+h)}{h} \cdot \frac{1}{\mathbb{P}(X > t)} = \frac{f_X(t)}{1 - F_X(t)}$$

即 ODE:

$$\lambda = \frac{F_X'(t)}{1 - F_X(t)}$$

with initial condition $F_X(0) = 0$.
我们知道这个 ODE 的 solution 是:

$$F_X(t) = \begin{cases} 1 - e^{-\lambda t}, & t > 0 \\ 0, & t \le 0 \end{cases}, \quad f_X(t) = \begin{cases} \lambda e^{-\lambda t}, & t > 0 \\ 0, & t \le 0 \end{cases}$$

Def 2.11 (exponential distribution)

我们称 X 为一个 **exponential random variable** with parameter λ, 如果它的 pdf is given by:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \le 0 \end{cases}$$

写作

$$X \sim \mathrm{Exp}(\lambda)$$

♣

刚才已经计算出, exponential random variable 的 distribution 为

$$F_X(x) = \begin{cases} \int_{-\infty}^{x} f(t)\,dt = \lambda \int_0^x e^{-\lambda t}\,dt = 1 - e^{-\lambda x}, & x > 0 \\ 0, \quad x < 0 \end{cases}$$

容易验证, $F_X(x) = 0$ when $x \to -\infty$, 以及 $F_X(x) \to 1$ when $x \to \infty$
计算其 expectation:

$$\begin{aligned} \mathbb{E}[X^n] &= \lambda \int_0^\infty x^n e^{-\lambda x}\,dx && (2.5) \\ &= -\int_0^\infty x^n (e^{-\lambda x})'\,dx && (2.6) \\ &= 0 + \int_0^\infty n x^{n-1} e^{-\lambda x}\,dx && (2.7) \\ &= \frac{n}{\lambda}\mathbb{E}(X^{n-1}) && (2.8) \end{aligned}$$

并 notice: $\mathbb{E}[X^0] = \mathbb{E}[1] = 1$. 因而 recursively get:

$$\mathbb{E}[X^n] = \frac{n!}{\lambda^n}$$

即: $\mathbb{E}[X] = \frac{1}{\lambda}, \mathbb{E}[X^2] = \frac{2}{\lambda^2}, \cdots$ 从而:

$$Var[X] = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

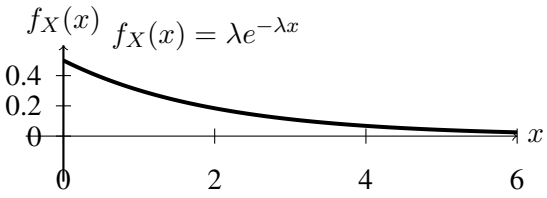

(a) pdf

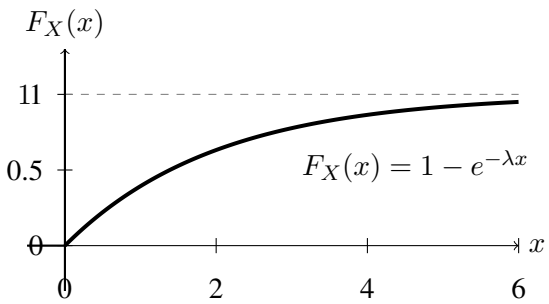

(b) cdf

Remark exponential 随机变量是 geometric 随机变量的 continuous analogue. 因为 geometric random variable 是假设一个事件在每个时间点以 constant 的概率发生, 用来 model 它第一次发生的时间;
而 exponential random variable 其实也是, 只是 on a continuous time scale: 它假设的 constant 损坏率其实 implies: **在任意时间, 如果灯还没坏, 那么灯此刻坏掉的概率是 constant 的.**

Theorem 2.6 (memoryless property of exponential distribution)

任意 continuous RV,

$$\mathbb{P}(X > b + t \mid X > b) = \mathbb{P}(X > t) \iff X \text{ is an exponential random variable}$$

♡

Proof 简单而言

$$P(X > b + t \mid X > b) = P(X > t) \tag{2.9}$$

$$\Longleftrightarrow P(X > b + t) = P(X > t)P(X > b) \tag{2.10}$$

$$\Longleftrightarrow X \text{ exponential} \tag{2.11}$$

因而对于 geometric RV 的 pmf, 当我们把时间间隔 (discrete time interval) 变得越来越小, 这一行为的极限就变为了 exponential RV 的 pdf.

这是一个很自然的 limit behavior, 此处不验证了.

Example 2.9 假设我们有一个 storage battery, 它的 lifetime 是 exponentially distributed 的, 并且 average 为 10 hours. Suppose 我们想要 use this battery for 5 hours for.

计算: probability of finishing the task, if:

(a) 使用一个 new battery

(b) 使用一个已经用过 2 hours 的 battery

Sol.

$$\mathbb{E}[X] = 10 = \frac{1}{\lambda} \implies \lambda = \frac{1}{10}$$

如果我们使用一个 new battery, 则 want: $P(X > 5) = 1 - P(X < 5) = 1 - F_X(5) = e^{-\frac{1}{2}}$ 如果我们使用一个用过 2 hours 的 battery, 则 want:

$$P(X > 5 + 2 \mid X > 2) = \frac{e^{-(5+2)\lambda}}{e^{-2\lambda}} = e^{-5\lambda} == e^{-\frac{1}{2}}$$

Notice:

$$P(X > 5) = P(X > 5 + 2 \mid X > 2)$$

2.4.3 Gamma distribution: negative binomial distribution 的 continuous version

recall Gamma 函数:

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x}\, dx$$

这个函数有一个重要的性质:

$$\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$$

因而对于 $n \in \mathbb{N}$, 我们有:

$$\Gamma(n) = (n - 1)!$$

Gamma 函数就是 factorial 函数的 continuous generalization.

Def 2.12 (Γ-distribution)

如果 continuous random variable X 的 pdf 是:

$$f_X(x) = \begin{cases} \dfrac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, & x > 0, \\ 0, & x \le 0 \end{cases}$$

那么我们称 X 服从 Γ **distribution**, 写作

$$X \sim \Gamma(\alpha, \lambda)$$

其中 $\alpha > 0$ 称为 shape parameter, $\lambda > 0$ 称为 rate parameter. ♣

Γ distribution 的 cdf 这样求: for $a \geq 0$,

$$\begin{aligned} F_X(a) = \int_{-\infty}^{a} f_X(x)\, dx &= \int_0^a \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}\, dx \\ &= \frac{1}{\Gamma(\alpha)} \int_0^{\lambda a} t^{\alpha-1} e^{-t}\, dt \end{aligned}$$

and for $a < 0$, $F_X(a) = 0$.

Expectation:

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{\Gamma(\alpha)} \int_0^\infty (\lambda x)^{\alpha-1} \lambda e^{-\lambda x}\, dx \\ &= \frac{1}{\lambda\Gamma(\alpha)} \int_0^\infty x^\alpha e^{-x}\, dx \\ &= \frac{\Gamma(\alpha+1)}{\lambda\Gamma(\alpha)} = \frac{\alpha}{\lambda} \end{aligned}$$

(since $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$.) 同理我们可以计算得: $\mathbb{E}[X^2] = \frac{\alpha(\alpha+1)}{\lambda^2}$ 从而

$$\mathrm{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{\alpha(\alpha+1)}{\lambda^2} - \frac{\alpha^2}{\lambda^2} = \frac{\alpha}{\lambda^2}$$

容易发现: 当 $\alpha = 1$ 时, Γ distribution 就退化成了 exponential distribution.

$$\Gamma(1, \lambda) = \mathrm{Exp}(\lambda)$$

而当 α 是一个正整数 n 时, Γ distribution 实际就是 n 个 independent exponential distribution 的 sum:

Proposition 2.13 (Gamma distribution 即是 independent exponential distribution 的 sum)

Let $X_1, X_2, \cdots, X_n \sim \mathrm{Exp}(\lambda)$ be i.i.d., 则

$$\Gamma(n, \lambda) = \sum_{i=1}^{n} X_i$$

♠

Proof 证明这一结论除了硬算之外, 更快的方法是通过 moment generating function. //TODO

Remark Gamma distribution 即多个 i.i.d. exponential distribution 的 sum; 而我们知道 exponential distribution 是 geometric distribution 的 continuous analogue; 因而 **Gamma distribution 也是 negative binomial distribution 的 continuous analogue.**

考虑固定 rate parameter $\lambda = 1$，不同 shape parameter α 的 Gamma distribution：

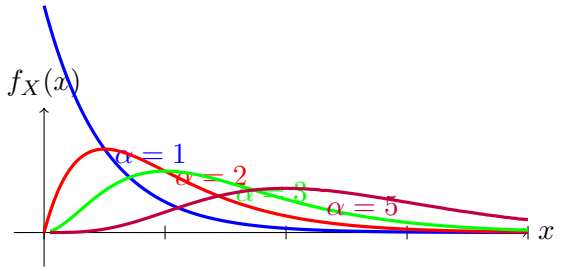

(a) pdf: $\lambda = 1$

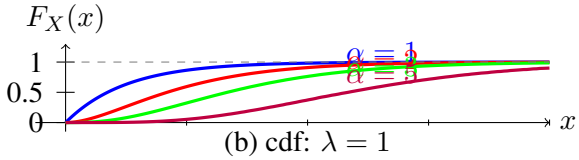

(b) cdf: $\lambda = 1$

- 当 $\alpha = 1$ 时, Gamma 分布退化为指数分布, pdf 单调递减;
- 随着 α 增大, pdf 从 0 处开始上升, 形成驼峰形状, 并逐渐向右平移;
- cdf 随 α 增大而上升变缓, 表示分布的右尾变长。

2.4.4 normal random variables: 最重要的 continuous RV, 任意 RV 的叠加极限

Def 2.13

我们称 X is **normally distributed with parameter** μ **and** σ, if the pdf of X is given by:

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

写作:

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

特别地, 当 $\mu = 0, \sigma = 1$ 时,

$$X \sim \mathcal{N}(0, 1)$$

被称为 **standard normal distribution.** ♣

- 验证其为 valid pdf:
  我们首先验证 standard normal distribution. 令:

$$I := \int_0^\infty e^{\frac{-y^2}{2}}\, dy$$

则

$$\begin{aligned} I^2 &= \int_0^\infty e^{\frac{-y^2}{2}}\, dy \cdot \int_0^\infty e^{\frac{-x^2}{2}}\, dx \\ &= \int_{\mathbb{R}^2_{\geq 0}} e^{-\frac{x^2+y^2}{2}}\, dx\, dy \\ &= \int_0^{\pi/2} \int_0^\infty e^{-\frac{r^2}{2}} r\, dr\, d\theta \\ &= \int_0^{\pi/2} \left(-e^{-\frac{r^2}{2}} \Big|_0^\infty \right) d\theta \\ &= \int_0^{\pi/2} 1\, d\theta = \frac{\pi}{2} \end{aligned}$$

从而得到 $I = \frac{\sqrt{2\pi}}{2}$. 因而 $\int_{-\infty}^\infty e^{-\frac{x^2}{2}}\, dx = \sqrt{2\pi}$, 因而 $\int_{\mathbb{R}} p(x)\, dx = 1$.
从而对于任意的 μ 和 σ, 通过 change of variable formula 易得 $\int_{\mathbb{R}} p(x)\, dx = 1$.

- 计算其 expectation 和 variance:
  我们只需要计算 standard normal distribution 的 expectation 和 variance, 然后通过 expectation 的 linearity 和 variance 的 scale invariance 来计算.
  令 $X \sim \mathcal{N}(0,1)$. Then
$$\mathbb{E}[X] = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x e^{-\frac{x^2}{2}}\, dx = 0$$
  因为这是一个 **odd function**. 从而
$$\begin{aligned}\mathbb{E}[X^2] &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^2 e^{-\frac{x^2}{2}}\, dx = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x(xe^{-\frac{x^2}{2}})\, dx = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x(e^{-\frac{x^2}{2}})'\, dx \\ &= -\frac{1}{\sqrt{2\pi}} x e^{-\frac{x^2}{2}} \Big|_{-\infty}^{\infty} + \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-\frac{x^2}{2}}\, dx = 0 + 1 = 1\end{aligned}$$
  从而:
$$\mathrm{Var}(X) = 1$$
  For general normally distributed Y, 我们知道了 $X := \frac{Y-\mu}{\sigma}$ 的 $\mathbb{E}[X] = 0$, $\mathrm{Var}(X) = 1$, 因而
$$\mathbb{E}[Y] = \mathbb{E}[\sigma X + \mu] = \mu$$
  and
$$\mathrm{Var}(Y) = \mathrm{Var}(\sigma X + \mu) = \mathbb{E}[(\sigma X + \mu - \mu)^2] = \mathbb{E}(\sigma^2 X^2) = \sigma^2 \mathbb{E}[X^2] = \sigma^2$$
  对于多个 i.i.d. normally distributed X,
$$\mathbb{E}[X^k] = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^k e^{-\frac{x^2}{2}}\, dx$$
  For k odd, it is 0.
  For k even:
$$\begin{aligned}\mathbb{E}[X^k] &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^{k-1}(xe^{-\frac{x^2}{2}})\, dx \\ &= -\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^{k-1}(e^{-\frac{x^2}{2}})'\, dx \\ &= 0 + \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} (x^{k-1})' e^{-\frac{x^2}{2}}\, dx \\ &= \frac{k-1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^{k-2} e^{-\frac{x^2}{2}}\, dx \\ &= (k-1)\mathbb{E}[X^{k-2}]\end{aligned}$$
  从而:
$$\mathbb{E}[X^k] = \begin{cases} 0, & k = 2j-1 \\ (2j-1)(2j-3)\cdots 1 = \frac{(2j)!}{2^j j!}, & k = 2j \end{cases}$$
- 其 cdf:
$$\Phi(a) := F_X(a) = \int_{(-\infty,a]} \rho(x)\, dx = \frac{1}{\sqrt{2\pi}} \int_{(-\infty,a]} e^{-\frac{x^2}{2}}\, dx$$
  我们在微积分中知道, 这个 integral 没有 closed form solution. 因而我们只能给出数值 approximation. Important numerical values:
$$\Phi(-3) \approx 0.0013; \quad \Phi(-2) \approx 0.023; \quad \Phi(-1) \approx 0.159$$

Note 由于 ρ (std) 是一个 even function, 有 $P(X < -1) = P(X > 1)$ 因而

$$P(X \text{ is one std dev from mean}) = 2(P(X < -1)) = 2\Phi(-1) \approx 0.32 = 32\%$$

Similarly,

$$P(X \text{ is two std dev from mean}) \approx 0.046 = 4.6\%$$

$$P(X \text{ is three std dev from mean}) \approx 0.0026 = 0.26\%$$

为什么 normal random variables 非常重要: 因为有一个 universality property called **central limit theorem.** 之后的章节我们会展开讨论:

任意的 random variable, 只要 expectation 和 variance 都是 finite 的, 那么它们的叠加极限都会服从 normal distribution.

这里我们先给出一个 special case of central limit theorem:

Theorem 2.7 (DeHavre's Central limit theorem for binomial distribution)

令 $S_n \sim \text{Bin}(n, p)$, 则

$$\lim_{n\to\infty} P\left(\frac{S_n - \mathbb{E}(S_n)}{\sigma(S_n)} \in (a, b)\right) = \Phi(b) - \Phi(a) = \frac{1}{\sqrt{2\pi}} \int_{(a,b)} e^{-\frac{x^2}{2}}\, dx$$

♡

(Proof: later chapters.)

Example 2.10 Toss a million times 一个 fair coin. Approximate the prob that we get more than 501000 heads:

$$\mathbb{E}(S_{1000000}) = np = 500000$$

$$\sigma(S_{1000000}) = \sqrt{npq} = 500$$

因而:

$$\begin{aligned}\mathbb{P}(S_{1000000} > 501000) &= \mathbb{P}(S_{1000000} - \mathbb{E}(S_{1000000}) > 1000) \\ &= \mathbb{P}\left(\frac{S_{1000000} - \mathbb{E}(S_{1000000})}{\sigma(S_{1000000})} > \frac{1000}{500}\right) \\ &\approx 1 - \Phi(2) = \Phi(-2) \approx 0.159\end{aligned}$$

除此之外 need to mention: Poission distribution 当 $\lambda \to \infty$ 时, 也得到 normal distribution.

这并不是一个令人惊讶的事情. 也可以用 central limit theorem 来解释. 因为 recall: Poisson distribution 有一个很重要的 property: additivity. 因而 $\lambda \to \infty$ 也可以看作 n 个 i.i.d. Poisson distribution 的 sum 在 $n \to \infty$ 时的极限行为, 从而通过 central limit theorem 得到 normal distribution.

2.4.5 summmary of discrete and continuous variables examples

distribution	**pmf / pdf**	**cdf**	$\mathbb{E}[X]$	**Var**(X)	**meaning**
Ber(p)	$\mathbb{P}(X = 1) = p$, $\mathbb{P}(X = 0) = 1 - p$	$F(x) = 1 - p, 0 \leq x < 1$	p	$p(1-p)$	一次 Bernoulli trial (unfair coin) 的结果
Bin(n, p)	$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$, $k = 0, \ldots, n$	$F(k) = \sum_{j=0}^{\lfloor k \rfloor} \binom{n}{j} p^j (1-p)^{n-j}$	np	$np(1-p)$	n 次 i.i.d. Bernoulli trials 中的成功次数
Geom(p)	$\mathbb{P}(X = k) = (1-p)^{k-1} p$, $k \geq 1$	$F(k) = 1 - (1-p)^k$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	Bernoulli trial 第一次成功所需的试验次数
NB(r, p)	$\mathbb{P}(X = k) = \binom{k+r-1}{k} (1-p)^k p^r$, $k \geq 0$	$F(k) = \sum_{j=0}^{k} \binom{j+r-1}{j} (1-p)^j p^r$	$\frac{r(1-p)}{p}$	$\frac{r(1-p)}{p^2}$	Bernoulli trial 在 r 次成功之前观察到的失败次数
Poi(λ)	$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$, $k \geq 0$	$F(k) = \sum_{j=0}^{k} e^{-\lambda} \frac{\lambda^j}{j!}$	λ	λ	fixed window (time/space) 下某一事件的计数
$U([a, b])$	$f(x) = \frac{1}{b-a}$, $a \leq x \leq b$	$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	uniform choice on an interval
Exp(λ)	$f(x) = \lambda e^{-\lambda x}$, $x \geq 0$	$F(x) = \begin{cases} 0, & x \leq 0 \\ 1 - e^{-\lambda x}, & x > 0 \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	固定平均发生率下，某事件第一次发生要等多久
$\Gamma(\alpha, \lambda)$	$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$, $x \geq 0$	$F(x) = \frac{1}{\Gamma(\alpha)} \int_0^{\lambda x} t^{\alpha-1} e^{-t}\, dt$	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$	α 个 i.i.d. exponential distributions 的和 (固定平均发生率下，第 α 次事件出现前要等多久)
$N(\mu, \sigma^2)$	$f(x) = 1/\sigma\sqrt{2\pi} \exp(-(x-\mu)^2/2\sigma^2)$	no elementary closed form	μ	σ^2	大量微小独立扰动 (测量误差/自然波动) 叠加后的结果