Module 3 joint and conditional distributions

3.1 random vector and joint distributions

3.1.1 random vector

Def 3.1 (random vector)

对于 prob space $(\Omega, \mathcal{F}, P)$, 一个 function $\mathbf{X}: \Omega \to \mathbb{R}^n$ 如果是一个 $(\mathcal{F}, \mathcal{B}(\mathbb{R}^n))$-measurable function, 则称它为一个 n-dimensional random variable, 或者 n-dimensional random vector.
通常我们将 random vector 写成分量形式

$$\mathbf{X}(\omega) = (X_1(\omega), X_2(\omega), \ldots, X_n(\omega))^T$$

♣

random vector 相当于在一个 prob space 上, 考虑多个重新分配 mass 的方法, 并把它们并列起来.

Proposition 3.1 (由 n 个 random variable 构成的 vector 是一个 random vector)

令 $X_1, X_2, \cdots, X_n$ 是定义在**同一个 prob space** $(\Omega, \mathcal{F}, \mathbb{P})$ 上的 n 个 random variables. 则函数 $\mathbf{X}: \Omega \to \mathbb{R}^n$ defined by

$$\omega \mapsto (X_1(\omega), X_2(\omega), \cdots, X_n(\omega))^T$$

是一个 random vector.

♠

Proof 我们在 measure theory 中证明过: 对于任意的 finite seq of Borel measureable functions $(f_i: \Omega \to \mathbb{R})_{i=1}^k$, 其各作为一个维度组成的函数 $f = (f_1, \cdots, f_k)$ 也是一个 Borel measurable function (from Ω 到 $\mathbb{R}^k$).

Proposition 3.2 (一个 random vector 的每个分量都是一个 random variable)

令 $\mathbf{X} = (X_1, X_2, \cdots, X_n)^T$ 是一个 random vector. 则对于任意 i, X_i 都是一个 random variable.

♠

Proof 对于 $\mathbf{X}: \Omega \to \mathbb{R}^n$ 是 $(\mathcal{F}, \mathcal{B}(\mathbb{R}^n))$-measurable, 我们可以将第 i 个分量 X_i 看作是 composition of two maps:

$$X_i = \pi_i \circ \mathbf{X}$$

其中 $\pi_i: \mathbb{R}^n \to \mathbb{R}$ projection map $\pi_i(x_1, \ldots, x_n) = x_i$.
由于 projection map π_i 是一个 Borel measurable function, 我们可以得出: $X_i = \pi_i(\mathbf{X})$ 也是一个 Borel measurable function, 也就是一个 random variable.

Remark 上两条 propositions 说明了一个事情: random vectors 和其分量 random variables 完全相互决定.

- **random variables 组合起来一定是一个 random vector.**
- **random vector 拆开每个分量一定是 random variable.**

因而, 研究一个 random vector 也就相当于研究分量 random variables 之间的关系.
这一章节我们会从 random vector 的性质 (比如 **joint distribution 和 marginal distribution, conditional distribution**) 出发, 研究分量 random variables 之间的关系.

(但是注意: 前提是这些 random variables 必须定义在同一个 prob space 上. 也就是, 它们的 base probability measure 一定相同. 如果我们考虑不同 prob space 上的 random variables 的话, 那它们没有一个公共的 base probability measure, 很难说它们之间有什么关系. 这种情况下, 我们需要 coupling: 构造一个新的 prob space (说白了就是 product space), 让这两个 random variables 都有一个新 version. 这一问题我们之后再讨论.)

3.1.2 joint distribution

Def 3.2 (joint distribution and joint cdf)

令 $X_1, \cdots, X_n$ 为 RV from the same prob space. 即 $\mathbf{X} := (X_1, \cdots, X_n)$ 是一个 random vector.
我们称 $\mathbb{P}^{\mathbf{X}} : \mathbb{R}^n \to \mathbb{R}$ defined by

$$\mathbb{P}^{\mathbf{X}}(B) = \mathbb{P}(\mathbf{X}^{-1}(B)), \quad \forall B \in \mathcal{B}(\mathbb{R}^n)$$

为 $X_1, \cdots, X_n$ 的 **joint distribution**.
而我们称 $F_{\mathbf{X}} = F_{X_1,\cdots,X_n} : \mathbb{R}^n \to \mathbb{R}$ defined by

$$F_{\mathbf{X}}(x_1, \cdots, x_n) = \mathbb{P}(X_1 \le x_1, \cdots, X_n \le x_n)$$

(即 $\mathbb{P}^{\mathbf{X}}$ restricted to the set of rectangles $\{(-\infty, x_1] \times \cdots \times (-\infty, x_n] : (x_1, \cdots, x_n) \in \mathbb{R}^n\}$) 为它们的 **joint distribution function (或称 joint cdf)**. ♣

joint distribution 的定义已经包括了如何从多个 random variables 的 distributions 得到一个 joint distribution. 而, 我们也可以从一个 joint distribution 的 limit behavior 得到每个 random variable 分量的 distributions, 称之为 marginal distribution:

Def 3.3 (marginal distribution)

令 $\mathbf{X} = (X_1, \cdots, X_n)^T$ 是一个 random vector. 则对于任意 i, X_i 的 distribution $\mathbb{P}^{X_i}$ 被称为 $\mathbf{X}$ 的第 i 个分量的 **marginal distribution**. ♣

我们以 $\mathbb{R}^2$ 为例. 得出的结论可以推广到 $\mathbb{R}^n$.

Proposition 3.3 (通过 joint distribution 的 limit behavior 得到 marginal distribution)

令 $\mathbf{X} = (X_1, X_2)^T$ 是一个 random vector. 则对于任意 $x \in \mathbb{R}$, 有

$$\mathbb{P}(X_1 \le x) = \lim_{y \to \infty} F_{\mathbf{X}}(x, y)$$

X_2 的 marginal distribution 也可以通过同样的方法得到.
此外, joint distribution 有其他明显的 limit behaviors:

- $$\lim_{x \to -\infty} F(x, y) = \lim_{y \to -\infty} F(x, y) = 0$$
- $F_{\mathbf{X}}$ 对于每个维度都是 increasing 且 right-continuous 的.
- $$\mathbb{P}(X \le x, Y \le y) = \lim_{z \uparrow y} F(x, z) = \lim_{z \uparrow x} F(z, y) = \lim_{z_1 \uparrow x, z_2 \uparrow y} F(z_1, z_2)$$

- $$\mathbb{P}(x_1 \le X \le x_2, y_1 \le Y \le y_2) = F(x_2, y_2) - F(x_1, y_2) = F(x_2, y_1) + F(x_1, y_1)$$ ♠

Remark 最后一条: 右边相当于

$$\mathbb{P}(x_1 < X < x_2, Y < y_2) - \mathbb{P}(x_1 < X < x_2, Y < y_1)$$

因而成立.

discrete random vector 很容易处理. 我们可以直接定义 joint pmf. 而 continuous random vector 需要展开讨论. 接下来我们讲单独讨论 continuous random vector 的 joint distribution.

3.1.3 condinuous joint cdf 与 joint pdf

recall: 一个随机变量 X 被称为一个 continuous random variable, 如果它的 cdf 是 absolutely continuous 的. 这个条件也等价于, 存在一个函数 $f_X : \mathbb{R} \to [0, \infty)$ 使得

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\, dt$$

这个定义可以 generalize 到 random vector 上.

Def 3.4 (continuous random vector 和 continuous joint cdf)

对于 random vector $\mathbf{X} = (X_1, \cdots, X_n)^T$ 如果 $\mathbb{P}^{\mathbf{X}} \ll \lambda^n$, 即存在一个函数 $f_{\mathbf{X}} : \mathbb{R}^n \to [0, \infty)$ 使得对于任意 Borel set $B \subseteq \mathbb{R}^n$, 有

$$\mathbb{P}^{\mathbf{X}}(B) = \int_B f_{\mathbf{X}}(x_1, \cdots, x_n)\, d\lambda^n(x_1, \cdots, x_n)$$

则称 $\mathbf{X}$ 是一个 **continuous random vector**.

注意: 由于是在 $\mathbb{R}^n$ 上, 这等价于存在一个函数 $f_{\mathbf{X}} : \mathbb{R}^n \to [0, \infty)$ 使得对于任意 $x_1, \cdots, x_n$, 有

$$F_{\mathbf{X}}(x_1, \cdots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f_{\mathbf{X}}(t_1, \cdots, t_n)\, dt_n \cdots dt_1$$

♣

Remark 这个函数 $f_{\mathbf{X}}$ 就是 continuous random vector $\mathbf{X}$ 的 **joint probability density function (joint pdf).** 它是 joint distribution measure $\mathbb{P}^{\mathbf{X}}$ 对于 Lebesgue measure λ^n 的 Radon-Nikodym derivative:

$$\frac{d\mathbb{P}^{\mathbf{X}}}{d\lambda^n} = f_{\mathbf{X}}$$

Remark 我们已经知道, 只要存在导数 $f_{\mathbf{X}}$ 可以对于任意 $\mathbf{x} \in \mathbb{R}^n$ 还原出 joint cdf $F_{\mathbf{X}}$ 的值, 那么 $f_{\mathbf{X}}$ 就是 joint pdf, 这个 random vector 就是一个 continuous random vector.

那么这个还原积分的计算可以任意换序吗?

显然是可以的. 因为 recall **Fubini's theorem**: 只要 f 绝对可积, 即 $\int_{\mathbb{R}^n} |f|\, d\lambda^n < \infty$, 那么对于任意的 permutation σ of $\{1, 2, \cdots, n\}$, 我们都可以将积分的顺序换成

$$\int_{-\infty}^{x_{\sigma(1)}} \cdots \int_{-\infty}^{x_{\sigma(n)}} f(t_1, \cdots, t_n)\, dt_{\sigma(n)} \cdots dt_{\sigma(1)}$$

而我们知道, f 一定是非负的, 而且积分一定是 1, 因而可以任意换序积分.

这就很舒服. 这也给出了 margin distribution 的计算方法: 只要对 joint pdf $f_{\mathbf{X}}$ 在其他维度上积分掉就行了.

Remark 注意: **多个 continuous random variables 的 joint distribution 不一定是 continuous 的.** 反例: 考

虑 random vector $\mathbf{X} = (X, X)^T$ where $X \sim \text{Uniform}(0,1)$ 则 $\mathbb{P}((X,X) \in \{y = x\}) = 1$. 而注意, $\{y = x\}$ 在 $\mathbb{R}^2$ 中的 Lebesgue measure 为 0, 而 absolute continuity 要求: 对于一个零测集, 其 $\mathbb{P}^{\mathbf{X}}$ 测度也必须是 0 (这是 $\mathbb{P}^{\mathbf{X}} \ll \lambda^n$ 的标准定义), 因而 joint distribution 不是 continuous 的.

Proposition 3.4 (joint pdf 和 joint cdf 的性质)

令 $\mathbf{X} = (X_1, \cdots, X_n)^T$ 是一个 continuous random vector, 则它的 joint pdf $f_{\mathbf{X}}$ 和 joint cdf $F_{\mathbf{X}}$ 有以下性质:

- $f_{\mathbf{X}} \geq 0$ a.e. 并且 $\int_{\mathbb{R}^n} f_{\mathbf{X}}\, d\lambda^n = 1$.
- (如果一个集合 A 有一个零测维度, 那么 $\mathbb{P}^{\mathbf{X}}(A) = 0$)
$$\mathbb{P}(X_1 = x_1, x_2 \leq X_2 \leq x_2' \cdots, x_n \leq X_n \leq x_n') = 0$$
- 每个 X_i 的 marginal distribution 也是 (absolutely) continuous 的, 并且
$$f_{X_i}(x) = \int_{\mathbb{R}^{n-1}} f_{\mathbf{X}}(t_1, \cdots, t_{i-1}, x, t_{i+1}, \cdots, t_n)\, dt_1 \cdots dt_{i-1} dt_{i+1} \cdots dt_n$$
例如,
$$f_X(x) = \int_{-\infty}^{\infty} f_{\mathbf{X}}(x, y)\, dy$$
- 对每个 $x_1, \cdots, x_n \in \mathbb{R}$, 都可以通过偏导数从 joint cdf 得到 joint pdf (这个偏导数一定 (a.e.) 存在):
$$f_{\mathbf{X}}(x_1, \cdots, x_n) = \frac{\partial^n}{\partial x_1 \cdots \partial x_n} F_{\mathbf{X}}(x_1, \cdots, x_n)$$
并且 by Fubini's theorem 可以 (a.e.) 任意换序:
$$\frac{\partial^n}{\partial x_{\sigma(1)} \cdots \partial x_{\sigma(n)}} F_{\mathbf{X}} \overset{a.e.}{=} f_{\mathbf{X}}$$

Proof

- 由于 $f_{\mathbf{X}}$ 是 $\mathbb{P}^{\mathbf{X}}$ 对于 λ^n 的 Radon-Nikodym derivative, 因为任何 Borel 集 B 都有 $P^{\mathbf{X}}(B) \geq 0$, 假设存在一个集合 $A \in \mathcal{B}(\mathbb{R}^n)$ 使得在其上 $f_{\mathbf{X}} < 0$ 且 $\lambda^n(A) > 0$, 那么根据积分定义
$$\mathbb{P}^{\mathbf{X}}(A) = \int_A f_{\mathbf{X}}\, d\lambda^n < 0$$
因而反证得 $f_{\mathbf{X}} \geq 0$ a.e.
并且
$$\int_{\mathbb{R}^n} f_{\mathbf{X}}\, d\lambda^n = \mathbb{P}^{\mathbf{X}}(\mathbb{R}^n) = 1$$
- natural.
- 即 marginal distribution 的定义在 continuous case 中的展开
- by Fubini's theorem, 以及 joint cdf 的定义.

Example 3.1 考虑
$$f_{X,Y}(x,y) = \begin{cases} ce^{-x}e^{-2y}, & \text{if } x, y > 0 \\ 0, & \text{otherwise} \end{cases}$$

Find c 使得这是一个合法的 joint pdf, 并且计算 X 和 Y 的 marginal pdfs, 以及 $\mathbb{P}(X > 1, Y < 1)$.

Sol. 我们需要

$$c\left(\int_0^\infty e^{-x}dx\right)\left(\int_0^\infty e^{-2y}dy\right)=1$$

evaluate 这两个积分:

$$\int_0^\infty e^{-x}dx=\left[-e^{-x}\right]_0^\infty=1,$$

$$\int_0^\infty e^{-2y}dy=\left[-\frac{1}{2}e^{-2y}\right]_0^\infty=\frac{1}{2}$$

因为 c 必须为 2.

计算 X 的 marginal pdf:

$$f_X(x)=\int_0^\infty 2e^{-x}e^{-2y}dy=2e^{-x}\left[-\frac{1}{2}e^{-2y}\right]_0^\infty=e^{-x}$$

然后计算 Y 的 marginal pdf:

$$f_Y(y)=\int_0^\infty 2e^{-x}e^{-2y}dx=2e^{-2y}\left[-e^{-x}\right]_0^\infty=2e^{-2y}$$

最后计算 $\mathbb{P}(X>1,Y<1)$:

$$\mathbb{P}(X>1,Y<1)=\int_1^\infty\int_0^1 2e^{-x}e^{-2y}dydx=\left(\int_1^\infty e^{-x}dx\right)\left(\int_0^1 2e^{-2y}dy\right)$$

这两个定积分分别为:

$$\int_1^\infty e^{-x}dx=\left[-e^{-x}\right]_1^\infty=e^{-1},$$

$$\int_0^1 2e^{-2y}dy=\left[-e^{-2y}\right]_0^1=1-e^{-2}$$

因而

$$\mathbb{P}(X>1,Y<1)=e^{-1}(1-e^{-2})=e^{-1}-e^{-3}$$

Theorem 3.1

对于 continuous random vector $\mathbf{X}=(X_1,\cdots,X_n)^T$, 取任意 Borel measurable function $g:\mathbb{R}^n\to\mathbb{R}$, 则 $g(\mathbf{X})$ 是一个 random variable, 并且如果 $\mathbb{E}[|g(\mathbf{X})|]<\infty$, 则, 则

$$\mathbb{E}[g(\mathbf{X})]=\int_{\mathbb{R}^n}g(\mathbf{x})f_{\mathbf{X}}(\mathbf{x})\,d\lambda^n(\mathbf{x})$$

♡

Example 3.2 Let (X,Y) be a two-dimensional random variable with joint density function

$$f_{X,Y}(x,y)=\begin{cases}1, & 0<\frac{y}{2}<x<1\\ 0, & \text{otherwise}\end{cases}$$

(a) 求 marginal density f_Y

(b) 计算概率 $\mathbb{P}(X=1/2)$ 和 $\mathbb{P}(X+Y\le 3/2)$

Sol.

(a) 对固定 y 需要满足 $0<y<2x$ 且 $x<1$, 等价于 $x>y/2$ 且 $x<1$. 因而 $0<y<2$

$$f_Y(y)=\int_{-\infty}^\infty f_{X,Y}(x,y)dx=\int_{y/2}^1 1dx=1-\frac{y}{2},\quad 0<y<2$$

否则 $f_Y(y)=0$.

(b) 由于 X 是一个 continuous random variable, $\mathbb{P}(X = 1/2) = 0$.
$\mathbb{P}(X + Y \leq 3/2)$ 略微难算一点: 满足条件的区域为 $\{(x, y) : 0 < \frac{y}{2} < x < 1, y \leq 3/2 - x\}$,

$$0 < y < \min(2x, 3/2 - x)$$

比较两条上界直线: $2x = 3/2 - x \Rightarrow x = 1/2$ 当 $0 < x < 1/2$, 有 $2x < 3/2 - x$, 所以上界是 $2x$; 当 $1/2 < x < 1$, 上界是 $3/2 - x$.
所以概率等于面积积分:

$$\mathbb{P}(X + Y \leq 3/2) = \int_0^{1/2} \int_0^{2x} 1 dy dx + \int_{1/2}^1 \int_0^{3/2-x} 1 dy dx$$

计算:

$$\int_0^{1/2} 2x dx = \left[x^2\right]_0^{1/2} = \frac{1}{4}$$

$$\int_{1/2}^1 \left(\frac{3}{2} - x\right) dx = \left[\frac{3}{2}x - \frac{x^2}{2}\right]_{1/2}^1 = 1 - \frac{5}{8} = \frac{3}{8}$$

合并得

$$\mathbb{P}(X + Y \leq 3/2) = \frac{1}{4} + \frac{3}{8} = \frac{5}{8}$$

也可以通过画图来做. 我们画出 support set 的图:

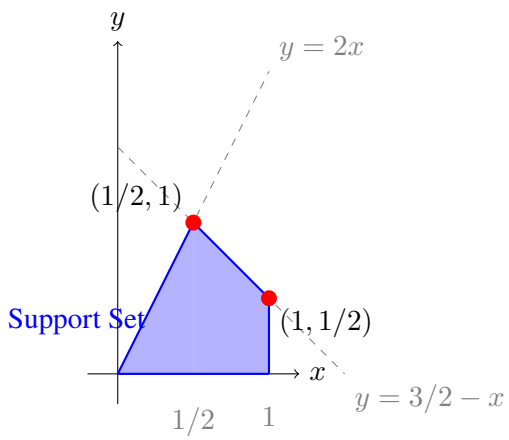

在这个图上对联合函数积分即可.

3.2 independence and correlation

3.2.1 independence

Def 3.5 (independence of random variables)

1 两个 random variables $X, Y : \Omega \to \mathbb{R}$ 被称为 independent 的, 如果对于任意的 Borel sets $A, B \subseteq \mathbb{R}$, 都有

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B)$$

即: **它们的 joint distribution 是它们 marginal distributions 的 product.** 注意, 这个定义等价于

$$F_{X,Y} = F_X F_Y$$

♣

Theorem 3.2 (discrete and continuous independence: joint density is product of marginal densities)

令 X, Y 是两个 random variables.

- 如果 X, Y 是 discrete random variables, 则它们 independent 的条件等价于对于任意 x, y, 都有
$$p_{X,Y} = p_X \cdot p_Y$$
- 如果 X, Y 是 continuous random variables, 则它们 independent 的条件等价于对于任意 x, y, 都有
$$f_{X,Y} = f_X \cdot f_Y$$

♡

Proof discrete case: 显然可得. continuous case: $F_{X,Y} = F_X F_Y \implies f_{X,Y} = f_X \cdot f_Y$: 取偏导数即可. $f_{X,Y} = f_X \cdot f_Y \implies F_{X,Y} = F_X F_Y$: 积分即可.

我们定义了两个 random variables 的 independence, 但是这个定义可以推广到多个 (甚至 uncountably many) random variables 上.

Def 3.6 (independence of multiple random variables)

令 $\{X_i : i \in I\}$ 是一个 random variables 的 family, 其中 I 是一个 index set. 则如果对于任意的 finite subset $J \subseteq I$, 以及对于任意的 Borel sets $\{A_j : j \in J\}$, 都有
$$\mathbb{P}(X_j \in A_j, \forall j \in J) = \prod_{j \in J} \mathbb{P}(X_j \in A_j)$$
则称这个 family of random variables 是 independent 的.

♣

注意: **joint density 的 factorization 也可以推广到多个 random variables 上.**

3.2.1.1 discrete RV independence 的 characterization

Remark 关于两个 discrete random variables X, Y 是否 independent 的判断, 还有一个直观的方法.

Proposition 3.5 (discrete RV independence 的 characterization)

两个 discrete random variables X, Y 是 independent 的 iff 它们的 joint pmf as a matrix 有 rank 1(每行每列都互为倍数).

♠

Proof note: 一个矩阵 M 的 rank 等于 1 iff 它可以被分解为两个向量的 outer product :
$$M = \mathbf{u}\mathbf{v}^\top$$
where $\mathbf{u}$ 和 $\mathbf{v}$ 是非零列向量.

($\implies$): 如果 independent, 那么对于所有 i, j, joint probability $p_{ij} = \mathbb{P}(X = x_i, Y = y_j)$ 满足:
$$p_{ij} = \mathbb{P}(X = x_i) \cdot \mathbb{P}(Y = y_j)$$
如果我们定义向量 $\mathbf{p}_X = [p_X(x_1), p_X(x_2), \dots]^\top$ 和 $\mathbf{p}_Y = [p_Y(y_1), p_Y(y_2), \dots]^\top$, 那么整个联合分布矩阵 P 就可以写成:
$$P = \mathbf{p}_X \mathbf{p}_Y^\top$$
这正是 Rank 1 矩阵的标准形式.

($\impliedby$) 如果 P 的 rank 为 1, 那么存在向量 $\mathbf{u}$ 和 $\mathbf{v}$ 使得 $p_{ij} = u_i v_j$. 由于 $\sum_{i,j} p_{ij} = 1$, 我们可以归一化这

两个向量, 使得 $\sum u_i = 1$ 且 $\sum v_j = 1$. 此时, u_i 恰好就是 X 的 marginal PMF, v_j 恰好就是 Y 的 marginal PMF. 因此满足 $p_{ij} = p_i \cdot p_j$, 即两个变量独立.

Example 3.3

$P =$

$X \backslash Y$	0	1	Marginal $\mathbb{P}(X)$
0	0.4	0.1	0.5
1	0.4	0.1	0.5
Marginal $\mathbb{P}(Y)$	0.8	0.2	1.0

这里的 X, Y 就是 independent 的 random variables.

3.2.1.2 continuous RV independence 的 geometric intuition

对于 independent continuous random variables X, Y, 它的 characterization 我们已经知道了: 即 joint pdf factorizes into marginal pdfs. 这一个 characterization 的 geometric intuition 是:

- joint pdf 的 support set 一定是一个矩形 (不一定 bounded)
- joint pdf 的**每个维度上的任意截面的形状都是一样的** (因为固定 x, 则 y 方向的性质只由 f_Y 决定.) 即: 固定 x, y-distribution 的横截面永远长得像 f_Y, 只是乘上了一个常数 $f_X(x)$ 而已. 同样的, 固定 y, x 分布的横截面永远长得像 f_X, 只是乘上了一个常数 $f_Y(y)$ 而已.

3.2.1.3 independence $\implies$ expectation is closed under product

Proposition 3.6 (independence $\implies$ expectation is closed under product)

令 $\{X_i : i \in I\}$ 是一个 independent 的 random variables 的 family, 则对于任意的 finite subset $J \subseteq I$, 以及对于任意的 Borel measurable functions $\{g_j : j \in J\}$, 如果 $\mathbb{E}[|g_j(X_j)|] < \infty$ for all $j \in J$, 则

$$\mathbb{E}\left[\prod_{j \in J} g_j(X_j)\right] = \prod_{j \in J} \mathbb{E}[g_j(X_j)]$$

♠

Proof 令 $J = \{1, 2, \ldots, n\}$. 由于 $X_1, \ldots, X_n$ 是 independent 的, 它们的 joint distribution $\mu_{\mathbf{X}}$ 是其 marginal distributions μ_{X_j} 的 product measure:

$$\mu_{\mathbf{X}} = \mu_{X_1} \times \mu_{X_2} \times \cdots \times \mu_{X_n}$$

根据 Change of Variables Formula,

$$\mathbb{E}\left[\prod_{j=1}^{n} g_j(X_j)\right] = \int_{\mathbb{R}^n} \left(\prod_{j=1}^{n} g_j(x_j)\right) d\mu_{\mathbf{X}}(x_1, \ldots, x_n) = \int_{\mathbb{R}} \cdots \int_{\mathbb{R}} \left(\prod_{j=1}^{n} g_j(x_j)\right) d\mu_{X_1}(x_1) \ldots d\mu_{X_n}(x_n)$$

由于被积函数 $\prod g_j(x_j)$ 是变量分离的, 根据 Fubini's Theorem 可以把积分分解成多个积分的 product:

$$= \left(\int_{\mathbb{R}} g_1(x_1)\, d\mu_{X_1}(x_1)\right) \times \cdots \times \left(\int_{\mathbb{R}} g_n(x_n)\, d\mu_{X_n}(x_n)\right)$$

其中每一项都是 $\mathbb{E}[g_j(X_j)]$.

Remark recall: expectation is a linear operator (因而 linearity 是 regardless of independence). 但是它不一定是一个 multiplicative operator.

而这里我们说, 如果 random variables 是 independent 的, 那么 expectation 就是一个 multiplicative operator.

3.2.2 covariance and correlation

Def 3.7 (covariance)

给定两个 random variables X, Y, 我们定义它们的 covariance 为

$$\mathrm{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

♣

Remark Covariance 丈量两个 random variables 之间的 linear relationship: 对于一个事件, X, Y 把它映射到的值是正相关的, 还是负相关的, 还是不相关的. Geometric intuition of covariance: 考虑取这两个 random variables 的一些 sample points 并分别作为 (x, y) 坐标.

- 如果它们的 covariance 是正的, 那么这些 sample points 倾向于拟合为一个斜率为正的 tendency line;
- 如果它们的 covariance 是负的, 那么这些 sample points 倾向于拟合为一个斜率为负的 tendency line;
- 如果它们的 covariance 是 0, 那么这些 sample points 倾向于拟合为一个水平的 tendency line.

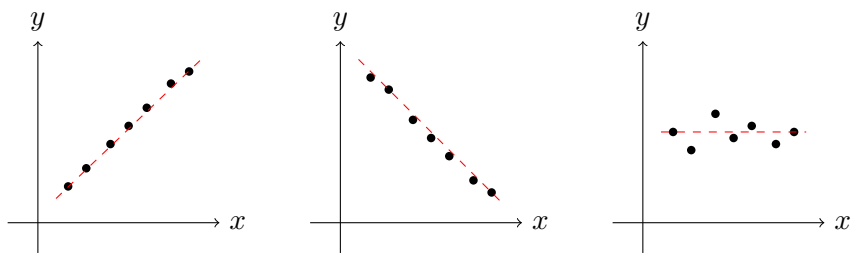

$\mathrm{Cov}(X, Y) > 0$ $\mathrm{Cov}(X, Y) < 0$ $\mathrm{Cov}(X, Y) = 0$

Proposition 3.7 (covariance 的基本性质: as a symmetric bilinear form (and inner product))

- independence $\implies$ zero covariance, 但是 zero covariance 不一定 $\implies$ independence.
- RV sum 的 variance 可分解成 variances 和 covariance:

$$\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\mathrm{Cov}(X, Y)$$

- covariance 是一个 **symmetric bilinear form** (并且 **translation-invariant**, 忽略 translation) 的 operator:

$$\mathrm{Cov}(aX + b, cY + d) = ac\,\mathrm{Cov}(X, Y)$$

$$\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$$

$$\mathrm{Cov}(X + Y, Z) = \mathrm{Cov}(X, Z) + \mathrm{Cov}(Y, Z)$$

- covariance 满足 positive semi-definiteness: $\mathrm{Cov}(X, X) = \mathrm{Var}(X) \geq 0$.

♠

Proof

- independence $\implies$ 期望的乘积等于乘积的期望, 因而 covariance 是 0. 但是 zero covariance 不一定 $\implies$ independence, 有一个经典反例: 考虑 X 是任意按原点对称的分布, 比如一个 standard normal distribution; 而定义 $Y = X^2$, 此时

$$\mathrm{Cov}(X, X^2) = E[X \cdot X^2] - E[X]E[X^2] = E[X^3] - E[X]E[X^2]$$

由于 X 的分布是关于原点对称的, $E[X^3] = 0$ 且 $E[X] = 0$, 因而 covariance 是 0. 但是 X 和 Y 显然不是 independent 的.

- $$\mathrm{Var}(X+Y) = \mathbb{E}\left[(X+Y)^2\right] - (\mathbb{E}[X+Y])^2 = \mathbb{E}\left[X^2\right] - (\mathbb{E}[X])^2 + \mathbb{E}\left[Y^2\right] - (\mathbb{E}[Y])^2 + 2(\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y])$$
- $$\mathrm{Cov}(aX+b, cY+d) = \mathbb{E}[(aX+b-\mathbb{E}[aX+b])(cY+d-\mathbb{E}[cY+d])] = \mathbb{E}[(aX-\mathbb{E}[aX])(cY-\mathbb{E}[cY])] = ac\,\mathrm{Cov}(X,Y)$$
- by def.
- by def.

Remark 第一条的反例值得注意. 这说明了 covariance 只能捕捉 linear relationship, 即趋势是否呈直线, 而不能捕捉 nonlinear relationship. 比如, 如果 (X, Y) 的联合分布 as a graph 是个圆圈, 那么 covariance 就是 0 而无法说明它们之间的关系.

为什么我们可以准确地说这是一种线性关系, 因为本质上, 我们既然说明了 covariance 是 (随机变量空间 $L^2(\Omega, \mathcal{F}, P)$ 上的) 一个 symmetric bilinear form, 并且它显然满足 positive semi-definiteness:

$$\mathrm{Cov}(X, X) = \mathrm{Var(X)} \geq 0$$

那么它就是一个合法的 inner product on $L^2(\Omega, \mathcal{F}, P)$. 更加准确而言, 这是一个 **inner product on the quotient space** $L^2(\Omega, \mathcal{F}, P)/\sim$, 其中 $\sim$ 是 equivalence relation: 所有只差一个 constant 的 random variables 都被认为是 equivalent 的, 被减去了它们自己的均值, 移动到了原点上. (这个 space 还是 complete 的 since L^2, 因而它其实是一个 Hilbert space. 原始的和 quotient 都是.)

原始 L^2 space 的内积:

$$\langle X, Y\rangle = \mathbb{E}[XY]$$

因而自然而言, 我们 work on 的 quotient space 的内积就应该是 covariance:

$$\langle X, Y\rangle_{\mathrm{Cov}} = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathrm{Cov}(X, Y)$$

在这个空间上, 由 covariance 这个 inner product induce 出的 norm 即为一个 random variable 的 standard deviation:

$$\|X\| = \sqrt{\mathrm{Var}(X)} = \sigma_X$$

而两个 random variables X, Y 之间的夹角 θ 的 cosine, 我们也专门做一个定义:

Def 3.8 (correlation)

$$\rho(X, Y) = \frac{\mathrm{Cov(X, Y)}}{\sqrt{\mathrm{Var}(X)}\sqrt{\mathrm{Var}(Y)}}$$

♣

显然,

$$\rho(X, Y) = \cos\theta$$

where θ 是 X, Y 之间的夹角. And we have:

$$\mathrm{Cov}(X, Y) = \sigma_X \sigma_Y \rho(X, Y)$$

从而有以下显然的结论:

- $\rho(X, Y) \in [-1, 1]$
- 如果 $\rho(X, Y) = 1$, 那么 $Y = aX + b$ for some $a > 0$ and b; 如果 $\rho(X, Y) = -1$, 那么 $Y = aX + b$ for some $a < 0$ and b.

- By Cauchy-Schwarz inequality, $|\mathrm{Cov}(X,Y)| \le \sigma_X \sigma_Y$.

Remark 我们刚才将 covariance 作为 inner product, 是在 quotient space $L^2(\Omega, \mathcal{F}, P)/\sim$ 上讨论; 而原始的 L^2 space 上的 inner product 是 $\mathbb{E}[XY]$. 这个原始 space 上的 Cauchy-Swartz 也值得一提:

$$\mathbb{E}\left[Z_1^2\right]\mathbb{E}\left[Z_2^2\right] \ge \left(\mathbb{E}\left[Z_1 Z_2\right]\right)^2$$

其中等号取得条件是 $Z_1 = aZ_2$ for some $a \in \mathbb{R}$. a 可以计算得是

$$a = \frac{\mathbb{E}\left[Z_1 Z_2\right]}{\mathbb{E}\left[Z_2^2\right]}$$

3.3 conditional distribution function and density

3.3.1 conditional distribution and its distribution function

Def 3.9 (conditional distribution)

给定 random variables $X, Y : \Omega \to \mathbb{R}$, 我们定义 the conditional distribution of X given $Y = y$ 为 the probability measure $\mathbb{P}^{X|Y=y}$:

$$\mathbb{P}^{X|Y=y}(A) := \lim_{h\to 0^+} \mathbb{P}(X \in A \mid y \le Y \le y+h), \quad \forall A \in \mathcal{B}(\mathbb{R})$$

并将 function $F_{X|Y=y} : \mathbb{R} \to \mathbb{R}$ defined by $F_{X|Y=y}(x) := \mathbb{P}^{X|Y=y}((-\infty, x])$:

$$F_{X|Y}(x|y) := \lim_{h\to 0^+} \mathbb{P}(X \le x \mid y \le Y \le y+h)$$

称为 the conditional distribution function of X given $Y = y$. ♣

Remark 注意: 每个取值 y 都对应一个 conditional distribution measure $\mathbb{P}^{X|Y=y}$ 和一个 conditional distribution function $F_{X|Y=y}$. 因此, conditional distribution 和 conditional distribution function 都是一个 family of measures/functions, 而不是一个 measure/function.

也就是说, 一个 random variable 可以 induce 出另一个 random variable 的可能 uncountably many 个 conditional distribution.

Remark 如果 X, Y 是两个 discrete random variables, 那么它们的 conditional distribution 就很简单了.

$$\mathbb{P}^{X|Y=y}(\{x\}) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}$$

以及

$$F_{X|Y=y}(x) = \sum_{t \le x} \frac{\mathbb{P}(X = t, Y = y)}{\mathbb{P}(Y = y)}$$

其他情况稍复杂一些. 但是我们可以确定的是:

3.3.2 conditional density for random variables jointly continuous

Theorem 3.3 (jointly continuous RVs 之间所有 defined 处总有 conditional density)

令 $\mathbf{X} = (X, Y)^T$ 是一个 continuous random vector, 则对于任意 y 使得 $f_Y(y) > 0$, 都有 conditional distribution of X given $Y = y$ 的 pdf:

$$f_{X|Y}(x|y) := \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

即: $\forall x \in \mathbb{R}$ 有:

$$F_{X|Y}(x|y) = \int_{-\infty}^{x} \frac{f_{X,Y}(t,y)}{f_Y(y)}\, dt$$

♡

Proof 注意: $(X, Y)^T$ 是 continuous random vector $\implies$ Y 是一个 continuous random variable. 因而因而 $f_Y(y)$ 是 well-defined 的. (反过来不成立) 取 y s.t. $f_Y(y) > 0$.
则

$$\begin{aligned}
\mathbb{P}^{X|Y=y}(A) &= \lim_{h\to 0^+} \mathbb{P}(X \in A \mid y \le Y \le y+h) \\
&= \lim_{h\to 0^+} \frac{\mathbb{P}(X \le x, y \le Y \le y+h)}{\mathbb{P}(y \le Y \le y+h)} = \lim_{h\to 0^+} \frac{F_{X,Y}(x, y+h) - F_{X,Y}(x,y)}{F_Y(y+h) - F_Y(y)} \\
&= \frac{\partial_y F_{X,Y}(x,y)}{f_Y(y)} = \int_{-\infty}^{x} \frac{f_{X,Y}(s,y)}{f_Y(y)} ds
\end{aligned}$$

因而, $f_{X|Y}(x|y) := \frac{f_{X,Y}(x,y)}{f_Y(y)}$ 是 $F_{X|Y=y}$ 的 pdf.

Remark 为了保证 continuous random vector 下分量之间的 conditional distribution 总是 (a.e.) 拥有 pdf 的, 我们可以给 not well-defined 处下定义: 如果 $f_Y(y) = 0$, 就直接 set $f_{X|Y}(x|y) = 0$ for all x.
在这个定义下: continuous random vector 下分量之间的 conditional distribution 也总是 continuous 的.

3.3.3 Law of Total Probability for continuous random vector

Theorem 3.4

令 $\mathbf{X} = (X, Y)^T$ 是一个 continuous random vector, 则对于任意 $A \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}((X,Y) \in A) = \int_{-\infty}^{+\infty} \mathbb{P}((X,y) \in A \mid Y = y) f_Y(y) dy$$

♡

Proof 注意:

$$\mathbb{P}\left(Y \in \{y \in \mathbb{R} : f_Y(y) = 0\}\right) = 0$$

即, $\left\{Y \in f_Y^{-1}(\{0\})\right\}$ 是一个 null set. (不是说 $f_Y(y) = 0$ 的 y 是 null set, 意思是说 Y 落在这些 y 上的事件是 null set.)

因而 compute:

$$\begin{aligned}
\mathbb{P}(X \in (-\infty, x], Y \le y) &= \mathbb{P}\left(X \in (-\infty, x], \{Y \le y\} \cap \left\{Y \notin f_Y^{-1}(\{0\})\right\}\right) = \int_{(-\infty,y]\cap f_Y^{-1}(\{0\}^c)} \int_{-\infty}^{\infty} f_{X,Y}(s,t)dsdt \\
&= \int_{(-\infty,y]\cap f_Y^{-1}((0,+\infty))} \left(\int_{-\infty}^{x} \frac{f_{X,Y}(s,t)}{f_Y(t)} ds\right) f_Y(t)dt \\
&= \int_{(-\infty,y]\cap f_Y^{-1}((0,+\infty))} \mathbb{P}(X \le x \mid Y = t) f_Y(t)dt \\
&= \int_{(-\infty,y]\cap f_Y^{-1}((0,+\infty))} \mathbb{P}(X \le x \mid Y = t) f_Y(t)dt + \int_{(-\infty,y]\cap f_Y^{-1}(\{0\})} \mathbb{P}(X \le x \mid Y = t) f_Y \\
&= \int_{(-\infty,y]} \mathbb{P}(X \le x \mid Y = t) f_Y(t)dt \\
&= \int_{-\infty}^{y} \mathbb{P}(X \le x \mid Y = t) f_Y(t)dt
\end{aligned}$$

Remark recall 最普通的全概率公式: 把样本空间 partition 成几个 disjoint 的事件 $B_1, \cdots, B_n$, 则任意事件 A 等于它在每个 B_i 上的 conditional probability 的和:

$$\mathbb{P}(A) = \sum_{i=1}^{n} \mathbb{P}(A \cap B_i) = \sum_{i=1}^{n} \mathbb{P}(A \mid B_i)\mathbb{P}(B_i)$$

这很容易理解. 而这里的 law of total probability for continuous random vector 就是这个公式在 continuous case 的推广:

由于在每一点 y 上, $(X,Y) \in A$ 的概率都有一个 conditional distribution $(X,Y) \in A | Y = y$, 因而 $(X,Y) \in A$ 的概率就等于这个 conditional distribution 在所有 y 上的加权和, 权重就是 Y 的 pdf $f_Y(y)$. 因而才有

$$\mathbb{P}((X,Y) \in A) = \int_{-\infty}^{+\infty} \mathbb{P}((X,y) \in A \mid Y = y) f_Y(y)dy$$

Example 3.4 考虑 random vector $\mathbf{X} = (X,Y)^T$ with joint pdf

$$f_{X,Y}(x,y) = \begin{cases} 4xy, & \text{if } 0 \le x \le 1, 0 \le y \le 1 \\ 0, & \text{otherwise} \end{cases}$$

计算: $f_X, f_Y, f_{X|Y}, f_{Y|X}$.

Sol. 首先计算 margianl pdfs:

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y)dy = \int_0^1 4xydy = 2x, \text{ for } 0 \le x \le 1$$

and

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y)dx = \int_0^1 4xydx = 2y, \text{ for } 0 \le y \le 1$$

由于这是一个 continuous random vector, 因而根据 3.3 可以得到:

$$f_{X|Y}(x \mid y) = \begin{cases} \frac{f_{X,Y}(x,y)}{f_Y(y)} = \frac{4xy}{2y} = 2x, & \text{if } x \in [0,1], \\ 0, & \text{otherwise.} \end{cases}$$

同理计算出

$$f_{Y|X}(y \mid x) = \begin{cases} \frac{f_{X,Y}(x,y)}{f_X(x)} = \frac{4xy}{2x} = 2y, & \text{if } y \in [0,1], \\ 0, & \text{otherwise.} \end{cases}$$

3.4 conditional expectation

Def 3.10 (conditional expectation)

令 $X, Y : \Omega \to \mathbb{R}$ 为 RVs. 对于 $y \in \mathbb{R}$ where $F_{X|Y} = \mathbb{P}^{X|Y=y}(X \leq x)$ is defined (这个条件对于 discrete 是筛选掉 $\mathbb{P}(y) = 0$ 的点, 对于 continuous 这是为了筛选掉 $f_Y = 0$ 的点), 我们定义 conditional expectation:

$$\mathbb{E}[X|Y = y] := \int_{-\infty}^{\infty} x \, d\mathbb{P}^{X|Y=y}(x)$$

特别地, 如果 (X, Y) 是一个 discrete random vector, 则它即是:

$$\mathbb{E}[X|Y = y] = \sum_x x\mathbb{P}(X|Y)(x|y) = \sum_x x\mathbb{P}(X = x|Y = y)$$

而如果 (X, Y) 是一个 (absolutely) continuous random vector, 则它即是:

$$\mathbb{E}[X|Y = y] = \int_{-\infty}^{\infty} x f_{X|Y}(x|y) \, dx$$

♣

Remark 注意: conditional expectation 对于给定的 y 是一个值; 而它也整体是一个 function of y, 同时也是 function from the sample space Ω (更准确而言是 $\{\omega \in \Omega : f_Y(Y(\omega)) > 0\}$, 但是去掉的这个集合的测度为零, 所以不用管, a.e. define 即可).
对于 $\omega \in \Omega$,

$$\mathbb{E}[X|Y] : \omega \mapsto \mathbb{E}[X|Y = Y(\omega)]$$

Notice: 这个函数是一个 random variable. 同理, 我们可以构造 conditional expectation given multiple random variables $\mathbb{E}[X|Y_1, \cdots, Y_n]$. 但是暂时不谈论这个.

Proposition 3.8 (independence 让 conditional distribution, density 和 expectation 都退化)

如果 X, Y 是 independent 的, 那么在任意 defined y 上,

$$F_{X|Y=y} = F_X, \quad f_{X|Y=y} = f_X,$$

以及

$$\mathbb{E}[X|Y] = \mathbb{E}[X]$$

♠

Example 3.5 (constant random variable 的 conditional expectation)
令 $X := b$ 为一个 constant random variable. Y 为一个 (absolutely) continuous random variable. compute: $\mathbb{E}[X|Y]$ when $f_Y(y) > 0$.
Sol.

$$F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y) = \begin{cases} F_Y(y), & \text{if } x \leq b, \\ 0, & \text{if } x > b \end{cases} = F_X(x) \cdot F_Y(y)$$

因而它们 independent (当然,,) 因而

$$\mathbb{E}[X|Y] = \mathbb{E}[X] = b$$

为什么我们要提及这个很呆的例子因为我们要说一个很呆但是要说一下的事情:

Proposition 3.9

conditional expectation 满足 linear property. 即任取 $a, b \in \mathbb{R}$,

$$\mathbb{E}[aX + b|Y] = a\mathbb{E}[X|Y] + b$$

♠

Example 3.6 (computation exercise) 令 X, Y 为 RVs with joint pdf

$$f_{X,Y}(x, y) = \begin{cases} \frac{1}{y}e^{-\frac{x}{y}}e^{-y}, & x > 0, y > 0 \\ 0, & \text{otherwise} \end{cases}$$

计算: $\mathbb{E}[X|Y = y]$.

Sol. 根据 3.3 和 3.10, 我们就是要做两件事情: 一个是计算 f_Y, 然后根据 f_Y 和 $f_{X,Y}$ 计算出 $f_{X|Y}$, 最后根据 $f_{X|Y}$ 积分计算出 $\mathbb{E}[X|Y]$.

那么

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)dx = e^{-y}\int_0^{+\infty} \frac{1}{y}e^{-x/y}dx = e^{-y}, y > 0$$

我们发现 $Y \sim \text{Exp}(1)$. 然后对于 $y > 0$,

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{1}{y}e^{-x/y}$$

因而 $X|Y = y \sim \text{Exp}(1/y)$. 最后,

$$\mathbb{E}[X \mid Y = y] = \int_{-\infty}^{+\infty} x f_{X|Y}(x \mid y)dx = \frac{1}{y}\int_0^{+\infty} xe^{-x/y}dx = y$$

而对于 $y \leq 0$, 因为 $f_Y(y) = 0$, $\mathbb{E}[X \mid Y = y]$ is not defined.

//TODO: 如果 X 是 continous 的, 而 Y 是 discrete 的, 那么我们怎么 define conditional distribution, 以及 expectation 呢?

3.5 law of total expectation

Theorem 3.5 (law of total expectation)

令 $X, Y : \Omega \to \mathbb{R}$ 为 RVs, 我们知道它们的 conditional expectation $\mathbb{E}[X|Y]$ 也是一个 $\Omega \to \mathbb{R}$ 的 RV. 如果 $\mathbb{E}[|\mathbb{E}[X|Y]|] < \infty$, 则

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]]$$

♡

Proof 对于更加严格的 conditional expectation 的定义而言 (as an orthogonal projection from $L^2(\Omega, \mathcal{F}, \mathbb{P})$ onto the subspace of Y-measurable functions), 这个定理是 trivial 的, 直接 follow from def. 在该定义中, $\mathbb{E}[X|Y]$ 被定义为一个 $\sigma(Y)$-measurable function Z, 使得对于任意 $A \in \sigma(Y)$, 都有

$$\int_A Z\, d\mathbb{P} = \int_A X\, d\mathbb{P}$$

那么取 $A = \Omega$, 自然得到.

而我们目前的定义下, 要证明它则要对于 discrete 和 continuous 两种情况分别计算证明. (recall Lebesgue Decomposition Theorem: 任意 measure 都可以被分解成一个 discrete 的部分和一个 continuous 的部分以及一个可以忽略的 singular 的部分. 因而证明了 discrete 和 continuous 两种情况即可.)

For discrete case:

$$\begin{aligned}\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}_\omega[\mathbb{E}[X \mid Y = Y(\omega)]] &= \mathbb{E}_\omega\left[\sum_x x\mathbb{P}(X = x \mid Y = Y(\omega))\right] \\ &= \sum_x x\mathbb{E}_\omega[\mathbb{P}(X = x \mid Y = Y(\omega))] \\ &= \sum_x x \sum_y \mathbb{P}(X = x \mid Y = y) \cdot \mathbb{P}(Y = y) \\ &= \sum_x x \sum_y \mathbb{P}(X = x, Y = y) \\ &= \sum_x x\mathbb{P}(X = x) = \mathbb{E}[X]\end{aligned}$$

For continuous case:

$$\begin{aligned}\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}_\omega\left[\int_{-\infty}^{+\infty} x f_{X|Y}(x \mid Y(\omega))dx\right] &= \int_{-\infty}^{+\infty} x\mathbb{E}_\omega\left[f_{X|Y}(x \mid Y(\omega))\right]dx \\ &= \int_{-\infty}^{+\infty} x \int_{-\infty}^{+\infty} f_{X|Y}(x \mid y) f_Y(y)dydx \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f_{X,Y}(x, y)dxdy \\ &= \int_{-\infty}^{+\infty} x \int_{-\infty}^{+\infty} f_{X,Y}(x, y)dxdx \\ &= \int_{-\infty}^{+\infty} x f_X(x)dx = \mathbb{E}[X]\end{aligned}$$

Example 3.7 (**fair coin toss**) 我们投掷一枚 fair coin. X_1: 直到 HH 出现钱, 投掷的次数;
X_2: 直到 HT 出现钱, 投掷的次数.
问题: 计算 $\mathbb{E}[X_1]$ 和 $\mathbb{E}[X_2]$.

Sol. We condition on 第一次 toss Y_1, 以及第二次 toss Y_2.

$$\begin{aligned}\mathbb{E}[X_1] = \mathbb{E}[\mathbb{E}[X_1 \mid Y_1]] &= \frac{1}{2}\mathbb{E}[X_1 \mid Y_1 = H] + \frac{1}{2}\mathbb{E}[X_1 \mid Y_1 = T] \\ &= \frac{1}{2}\left(\frac{1}{2}\mathbb{E}[X \mid Y_1 = H, Y_2 = H] + \frac{1}{2}\mathbb{E}[X \mid Y_1 = H, Y_2 = T]\right) + \frac{1}{2}(1 + \mathbb{E}[X_1]) \\ &= \frac{1}{2}\left(\frac{2}{2} + \frac{1}{2}(\mathbb{E}[X_1] + 2)\right) + \frac{1}{2}(1 + \mathbb{E}[X_1]).\end{aligned}$$

解出 $\mathbb{E}[X_1] = 6$. 同理, 可以解出 $\mathbb{E}[X_2] = 4$.

Example 3.8 一只鸡在一段时间内下 N 个蛋, 其中 $N \sim \text{Pois}(\lambda)$. 每只蛋孵化成小鸡的概率为 p, 互相独立. 令 K 表示孵化成小鸡的蛋的数量, 计算 $K|N, \mathbb{E}[K]$, 以及 K 的 distribution.

Sol. 由题意得

$$\mathbb{P}(K = k|N = n) = \binom{n}{k} p^k (1 - p)^{n-k}$$

因此, $K|N = n \sim \text{Bin}(n, p)$ 因而 $\mathbb{E}[K|N = n] = np$. 由 law of total expectation,

$$\mathbb{E}[K] = \mathbb{E}[\mathbb{E}[K|N]] = \mathbb{E}[N] \cdot p = \lambda$$

然后由 law of total probability,

$$\begin{aligned}
\mathbb{P}(K=k) &= \sum_{n=k}^{+\infty} \mathbb{P}(K=k, N=n) = \sum_{n=k}^{+\infty} \mathbb{P}(K=k|N=n)\cdot\mathbb{P}(N=n) \\
&= \sum_{n=k}^{+\infty} \binom{n}{k} p^k (1-p)^{n-k} \cdot \frac{\lambda^n e^{-\lambda}}{n!} \\
&= \sum_{n=k}^{+\infty} \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \cdot \frac{\lambda^n e^{-\lambda}}{n!} \\
&= \sum_{n=k}^{+\infty} \frac{\lambda^n e^{-\lambda}}{k!(n-k)!} p^k (1-p)^{n-k} \\
&= \sum_{n=k}^{+\infty} \frac{(\lambda p)^k (\lambda(1-p))^{n-k} e^{-\lambda}}{k!(n-k)!} \\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!} \sum_{n=k}^{+\infty} \frac{(\lambda(1-p))^{n-k}}{(n-k)!} \\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!} \sum_{m=0}^{+\infty} \frac{(\lambda(1-p))^{m}}{m!} \\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!} \cdot e^{\lambda(1-p)} = \frac{(\lambda p)^k e^{-\lambda p}}{k!}
\end{aligned}$$

因而 $K \sim \text{Pois}(\lambda p)$.

Example 3.9 令 (X, Y) 为一对 continuous RVs with joint pdf:

$$f_{X,Y}(x,y) = 2e^{-(x+2y)}\mathbf{1}_{\{x>0, y>0\}}$$

首先, verify $f_{X,Y}$ is a valid joint pdf, 然后计算 $\mathbb{E}[X|Y=y]$ 和 $\mathbb{E}[X]$.

Sol.

$$\int_0^\infty \int_0^\infty 2e^{-(x+2y)} dx dy = \int_0^\infty 2e^{-2y} \left(\int_0^\infty e^{-x} dx \right) dy = \int_0^\infty 2e^{-2y} dy = 1$$

verify 很简单. 然后我们首先计算 density of Y:

$$f_Y(y) = \int_0^\infty 2e^{-(x+2y)} dx = 2e^{-2y}, \quad y > 0$$

然后计算 conditional density of X given $Y = y$:

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x,y)}{f_Y(y)} = e^{-x}, \quad x > 0$$

因而 by 3.10,

$$\mathbb{E}[X \mid Y = y] = \int_0^\infty x e^{-x} dx = 1$$

然后 by law of total expectation,

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]] = \mathbb{E}[1] = 1$$

since $\mathbb{E}[X|Y]$ is a constant function.